



INSTITUTO POLITÉCNICO
DE COIMBRA

INSTITUTO SUPERIOR
DE ENGENHARIA
DE COIMBRA



Instituto Superior de Engenharia

Politécnico de Coimbra

DEPARTAMENTO DE FÍSICA E MATEMÁTICA

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

Trabalho de Projeto para a obtenção do grau de Licenciado em
Engenharia Biomédica - Bioeletrónica

Autor

Nuno Manuel Lourenço Pires

Orientador

Milton Augusto Morais Sarmento Pato de Macedo

Coimbra, 25 de julho de 2023

RESUMO

Este relatório aborda a implementação e avaliação de um sistema bimodal de aquisição de sinais EMG-FMG para o controlo de uma mão biónica, no âmbito do projeto Open Source Bionic Hand. O principal objetivo foi otimizar o reconhecimento de gestos e melhorar o controle de próteses mioelétricas, contrariando as limitações do uso exclusivo de sensores EMG. A metodologia utilizada envolveu a aquisição simultânea de dados EMG e FMG, a otimização das rotinas de processamento de sinal no MATLAB e a comparação de vários modelos de Machine Learning utilizando a ferramenta Classification Learner do MATLAB. Os modelos Quadratic SVM, Cubic SVM, Weighted KNN e Fine KNN destacaram-se pela sua precisão, F-score e área sob a curva ROC. Apesar dos desafios encontrados, tais como a fixação dos sensores e a variabilidade na execução dos gestos, os resultados sugerem um potencial promissor para a combinação de EMG e FMG no controle de próteses de mão. Como trabalho futuro, recomenda-se a melhoria do sistema de fixação dos sensores e a realização de estudos com conjuntos de teste mais amplos para garantir uma maior representatividade e robustez dos resultados.

Palavras-chave: próteses mioelétricas, EMG, FMG, Machine Learning, mão biónica, reconhecimento de gestos

ABSTRACT

This report addresses the implementation and evaluation of a bimodal EMG-FMG signal acquisition system for the control of a bionic hand, as part of the Open Source Bionic Hand project. The main objective was to optimize gesture recognition and enhance the control of myoelectric prostheses, overcoming the limitations associated with the exclusive use of EMG sensors. The methodology used involved simultaneous acquisition of EMG and FMG data, the optimization of signal processing routines in MATLAB, and the comparison of various Machine Learning models using the MATLAB Classification Learner tool. The Quadratic SVM, Cubic SVM, Weighted KNN, and Fine KNN models stood out for their *accuracy*, F-score, and area under the ROC curve. Despite the challenges encountered, such as sensor fixation and variability in gesture execution, the results suggest promising potential for the combination of EMG and FMG in hand prosthesis control. Future work recommends improving the sensor fixation system and conducting studies with larger test sets to ensure greater representativeness and robustness of the results.

Keywords: myoelectric prostheses, EMG, FMG, Machine Learning, bionic hand, hand gesture recognition.

ÍNDICE

Resumo	i
Abstract.....	ii
Índice.....	iii
Índice de tabelas	v
Índice de figuras.....	vi
Lista de siglas e acrónimos	viii
1 Introdução	1
1.1 Contexto do Projeto	1
1.2 Objetivos do Projeto.....	1
1.3 Estrutura do Relatório	2
2 Enquadramento Teórico.....	3
2.1 Anatomia e funções musculares do antebraço	3
2.2 Movimentos da mão	6
2.3 Eletromiografia (EMG)	7
2.3.1 Sinal mioelétrico	7
2.3.2 Características do sinal EMG.....	9
2.3.3 Aquisição do Sinal sEMG	10
2.3.4 Processamento do Sinal EMG.....	13
2.3.5 Características do Ruído em sEMG.....	15
2.4 Force Myography (FMG)	16
2.4.1 Fundamentos e aplicações em próteses biônicas	16
2.4.2 Aquisição de sinais FMG.....	17
2.4.3 Processamento de sinais FMG	17
2.5 Introdução à Classificação em Reconhecimento de Padrões.....	18
2.6 Próteses biônicas de membro superior comerciais	19
3 Metodologia.....	23
3.1 Descrição da População e dos Gestos Estudados.....	23
3.2 Hardware e software	24
3.2.1 BITalino (r)evolution e OpenSignals	24
3.2.2 Sensor EMG	25
3.2.3 FSR 402	26

3.2.4	MATLAB e app Classification Learner	27
3.3	Aquisição dos sinais	28
3.3.1	Condicionamento dos sinais FMG	28
3.3.2	Procedimento de Aquisição dos Sinais	29
3.4	Processamento dos sinais e extração de características	30
3.5	Seleção e aplicação de classificadores	33
3.6	Métricas de desempenho	34
3.6.1	Accuracy	34
3.6.2	Precisão e Sensibilidade (componentes do F-score)	35
3.6.3	F-score	35
3.6.4	Área sob a Curva ROC (ROC-AUC).....	36
4	Resultados	37
4.1	Comparação de classificadores	37
4.2	Impacto da Seleção de Características	39
4.3	Otimização dos melhores modelos	43
4.4	Comparação dos resultados de características EMG e FMG	58
5	Discussão dos resultados	61
6	Conclusões e trabalho futuro	63
	Referências bibliográficas	64
	Anexos	70
	Anexo A – Póster das Jornadas de Biomédica.....	71
	Anexo B – Rotina MATLAB: main.m	72
	Anexo C – Rotina MATLAB: onsetting.m	76
	Anexo D – Rotina MATLAB: extract_emg_features.m.....	78
	Anexo E – Rotina MATLAB: extract_fmg_features.m.....	79
	Anexo F – Seleção de caraterísticas.....	80
	Anexo G – Rankings de caraterísticas.....	82

ÍNDICE DE TABELAS

Tabela 2.1 – Músculos do antebraço.....	3
Tabela 2.2 – Resumo das ações dos músculos do antebraço.....	5
Tabela 2.3 – Exemplos de gestos envolvendo músculos extrínsecos da mão.	7
Tabela 3.1 – BITalino (r)evolution: especificações técnicas.....	24
Tabela 3.2 – Especificações técnicas do sensor EMG.....	26
Tabela 3.3 – Características extraídas dos sinais EMG e FMG.....	31
Tabela 4.1 – Avaliação inicial de desempenho dos classificadores.	37
Tabela 4.2 – F-score e ROC-AUC dos classificadores selecionados.	38
Tabela 4.3 – Desempenho de validação dos modelos para diferentes métodos de ranking de características e número de características.	41
Tabela 4.4 – Desempenho de teste dos modelos para diferentes métodos de ranking de características e número de características.	42
Tabela 4.5 – Diferenças entre parâmetros e hiperparâmetros.	43
Tabela 4.6 – Detalhes do ajuste de hiperparâmetros.	45
Tabela 4.7 – Impacto do ajuste de hiperparâmetros na performance dos modelos.	46
Tabela 4.8 – Desempenho dos Modelos: <i>accuracy</i> , F-Score e ROC-AUC.....	46
Tabela 4.9 – Comparação da <i>accuracy</i> dos classificadores entre utilização de todos os dados, somente EMG e somente FMG.	58

ÍNDICE DE FIGURAS

Figura 2.1 – Terminologia dos movimentos da mão (carpo) e dedos.	6
Figura 2.2 – O sinal sEMG corresponde ao somatório dos trens de potenciais de ação das unidades motoras detetados na área de alcance dos elétrodos.	9
Figura 2.3 – Exemplo de sinal EMG bruto e histograma de amplitudes. Este sinal obedece a uma distribuição Gaussiana com média de 0 [mV].....	9
Figura 2.4 – Espectros de potência de sinais sEMG em gestos da mão, em dB....	10
Figura 2.5 – Etapas da aquisição de sEMG: (1) deteção dos potenciais com elétrodos de superfície e um elétrodo de referência; (2) amplificação desses potenciais com amplificadores diferenciais; (3) filtragem analógica para evitar <i>aliasing</i> ; (4) amostragem temporal e conversão A/D do sinal EMG e (5) posterior transmissão para computador.....	10
Figura 2.6 – Ilustração dos tempos de <i>onset</i> e <i>offset</i> do sinal EMG.	14
Figura 2.7 – Circuito divisor de tensão seguido de <i>buffer</i>	17
Figura 2.8 – i-Limb da Touch Bionics (2009).....	20
Figura 2.9 – Bebionic, introduzida pela RSLSteeper (2010).	20
Figura 2.10 – Michelangelo Hand (2011)	21
Figura 2.11 – DEKA/Luke Arm (em configuração humeral).....	21
Figura 2.12 – Hero Arm da Open Bionics.	22
Figura 3.1 – Gestos utilizados para classificação: a) Abertura da mão; b) Fecho da mão (em punho); c) <i>3-point pinch</i> ; d) <i>Thumbs-up</i> ; e) Apontar.	24
Figura 3.2 – BITalino (r)evolution Core BT.	24
Figura 3.3 – Visualização no OpenSignals de um ficheiro de dados previamente armazenado, mostrando sinais EMG (em cima) e FMG (em baixo) para o gesto “abertura da mão”.	25
Figura 3.4 – Sensor EMG do BITalino: a) Versão com conexões UC-E6; b) Pin-out.	25
Figura 3.5 – Sensor FSR 402.....	26
Figura 3.6 – FSR 402: a) Divisor de tensão com <i>buffer</i> ; b) Curvas de tensão de saída vs. força para diferentes valores de R_M , em configuração de divisor de tensão e com V_+ de +5 V.....	27
Figura 3.7 – Circuito dos sinais FMG: a) Visão afastada, com sensores; b) Visão das ligações.....	29
Figura 3.8 – Aquisição de sinais: a) No fecho da mão; b) Na abertura da mão.	30

*Reconhecimento de gestos através da implementação de sistema bimodal de aquisição
de sinais EMG e FMG*

Figura 3.9 – Plots de sinais EMG e FMG obtidos na execução do gesto “abertura da mão”.....	33
Figura 3.10 – Exemplo de matriz de confusão para classificadores binários.....	35
Figura 3.11 – Curvas ROC (teste) para as várias classes do modelo Weighted KNN optimizado.....	36
Figura 4.1 – Matriz de confusão (validação): Weighted KNN.	49
Figura 4.2 – Matriz de confusão (teste): Weighted KNN.	50
Figura 4.3 – Matriz de confusão (validação): Quadratic SVM.	51
Figura 4.4 – Matriz de confusão (teste): Quadratic SVM.	52
Figura 4.5 – Matriz de confusão (validação): Cubic SVM.	53
Figura 4.6 – Matriz de confusão (teste): Cubic SVM.	54
Figura 4.7 – Matriz de confusão (validação): Fine KNN.	55
Figura 4.8 – Matriz de confusão (teste): Fine KNN.	56
Figura 4.9 – Matriz de confusão (validação): Wide Neural Network.	57
Figura 4.10 – Matriz de confusão (teste): Wide Neural Network.	58

LISTA DE SIGLAS E ACRÓNIMOS

A/D	Analog to Digital
ANOVA	Analysis of Variance
CMRR	Common Mode Rejection Ratio
DC	Direct Current
ECG	Eletrocardiografia
EMG	Eletromiografia
FMG	Force Myography
FSR	Force-Sensitive Resistor
IAV	Integral of Absolute Value
ISEC	Instituto Superior de Engenharia de Coimbra
KNN	k-Nearest Neighbors
MAV	Mean Absolute Value
mRMR	minimum Redundancy Maximum Relevance
MUAP	Motor Unit Action Potential
NN	Neural Network
PSD	Power Spectrum Density
ROC	Receiver Operating Characteristic
ROC-	
AUC	Receiver Operating Characteristic - Area Under the Curve
sEMG	Eletromiografia de superfície

1 INTRODUÇÃO

1.1 Contexto do Projeto

A investigação na área das próteses mioelétricas confronta-se com o desafio constante de replicar a funcionalidade da mão humana. Contudo, o reconhecimento de gestos, assente na atividade elétrica dos remanescentes musculares e captada por sensores eletromiográficos de superfície (EMG), pode ser prejudicado por fatores como ruído eletromagnético, fadiga muscular e alterações na interface sensor-pele.

Este estudo integra-se num projeto mais amplo, o Open Source Bionic Hand, cujo objetivo é desenvolver e controlar, em tempo real, um protótipo de mão biónica de baixo custo imprimido em 3D, utilizando sinais provenientes dos músculos do antebraço. Neste trabalho, pretende-se implementar um sistema bimodal de aquisição de sinais, que recorre a sinais EMG e a Force Myography (FMG), com vista a optimizar o reconhecimento da intenção de gestos e, por consequência, o controlo da mão biónica.

Uma apresentação inicial deste trabalho (que pode consultar no Anexo A) foi feita nas Jornadas de Engenharia Biomédica de 2023 do ISEC e o trabalho encontra-se em preparação para ser submetido ao RECPAD 2023¹, conferência anual sobre reconhecimento de padrões.

1.2 Objetivos do Projeto

O objetivo principal deste projeto é a implementação e avaliação da eficácia de um sistema bimodal de aquisição de sinais EMG-FMG para o controlo de uma mão biónica. A ideia é contrariar as limitações dos sensores EMG, integrando a FMG, que mostra benefícios como robustez face às mudanças de impedância na interface da pele e sudorese, e menor sensibilidade ao posicionamento do sensor. Isto apesar de ter os seus próprios desafios, tais como sensibilidade a movimentos não intencionais e ruídos externos.

Neste contexto, os objetivos específicos deste projeto incluem:

- i. A aquisição simultânea de dados EMG e FMG, utilizando o BITalino e o OpenSignals.
- ii. Optimização das rotinas MATLAB de processamento de sinal e deteção de *onset/offset* dos sinais adquiridos. Estas são etapas cruciais para a extração de características.

¹ <https://recpad2023.isec.pt/>.

- iii. Utilização das características extraídas para treinar e comparar modelos de Machine Learning no reconhecimento de gestos, através da ferramenta Classification Learner do MATLAB.

1.3 Estrutura do Relatório

Este relatório começa com uma contextualização teórica dos conceitos-chave, incluindo a anatomia e funções musculares do antebraço, movimentos da mão, EMG, FMG, e um olhar sobre as próteses biónicas de membro superior comerciais existentes (Capítulo 2). Segue-se a apresentação da metodologia adotada para este projeto, com a descrição da população-alvo e dos gestos estudados, o hardware e software utilizados, os processos de aquisição e condicionamento de sinais, processamento de sinais e extração de características, além da seleção e aplicação de classificadores, e das métricas de avaliação utilizadas (Capítulo 3). Posteriormente, o relatório foca-se nos resultados, explorando a comparação de classificadores, o impacto da seleção de características, a otimização dos melhores modelos e a comparação dos resultados entre características EMG e FMG (Capítulo 4). O Capítulo 5 discute os resultados obtidos, avalia o impacto das estratégias usadas e sublinha as principais descobertas. Finalmente, o relatório encerra com conclusões, resumindo as principais descobertas e delineando possíveis direções para futuras pesquisas (Capítulo 6). As referências bibliográficas completam o relatório.

2 ENQUADRAMENTO TEÓRICO

2.1 Anatomia e funções musculares do antebraço

Em anatomia, o antebraço é o segmento do membro superior que se estende do cotovelo até ao punho (nome vulgar pelo qual é conhecido o carpo). Dele fazem parte dois ossos longos situados lado a lado, o rádio e o cíbito (ou ulna), unidos por uma membrana interóssea fina. Esta estrutura serve uma dupla função, pois para além de ser a principal responsável por unir firmemente e permitir a estabilidade axial dos ossos, é responsável pela inserção proximal de alguns músculos profundos do antebraço (Moore et al., 2017).

De acordo com Marieb et al. (2014), o antebraço encontra-se dividido em dois compartimentos anatómicos principais por um tecido conjuntivo denso chamado fáscia; um compartimento anterior flexor-pronador e um posterior extensor-supinador. Ambos os compartimentos/ grupos, por sua vez, contêm uma camada muscular superficial e uma camada muscular profunda. No entanto, esta classificação apresenta variações entre autores. Esperança Pina (1999), por exemplo, considera a existência de um grupo externo “constituído por quatro músculos que são indo da superfície para a profundidade, o longo supinador [nomenclatura antiga, atualmente chamado de braquiorradial], o 1º radial ou longo radial [extensor radial longo do carpo], o 2º radial externo ou curto radial [extensor radial curto do carpo] e o curto supinador [supinador]”. Moore et al. (2017) apresenta o músculo flexor superficial dos dedos numa camada intermédia. A Tabela 2.1 apresenta a distribuição dos músculos no antebraço e as suas ações motoras.

Tabela 2.1 – Músculos do antebraço.

Grupo	Camada	Músculo	Ação
Anterior	Superficial	Pronador redondo	Realiza a pronação ¹ do antebraço; flexor fraco do antebraço
		Flexor radial do carpo	Flexor potente da mão (no carpo); abdução ² da mão
		Palmar longo	Tensiona a pele e a aponeurose palmar; flexor fraco da mão; sinergista ³ fraco na flexão do antebraço
		Flexor comum superficial dos dedos	Flexiona a mão e falanges médias dos 2º-5º dedos

¹ Rotação do antebraço de modo que a palma da mão fique para dentro.

² Movimento para fora, relativamente à linha média.

³ Auxiliam os motores principais, evitam movimentos indesejáveis ou estabilizam as articulações.

Grupo	Camada	Músculo	Ação
		Flexor ulnar do carpo	Flete e aduz ¹ a mão com o extensor ulnar do carpo (músculo posterior); estabiliza o carpo durante a extensão dos dedos
Profunda	Flexor comum profundo dos dedos		Flexiona as articulações interfalângicas distais dos 2º-5º dedos; flexor de ação lenta de qualquer um ou de todos os dedos; auxilia na flexão da mão
		Flexor longo do polegar	Flexiona as falanges do polegar
	Pronador quadrado		Agonista ² da pronação do antebraço e da mão; age com o pronador redondo; também auxilia a unir a ulna e o rádio
Posterior	Superficial	Braquiorradial	Flexão fraca do antebraço na articulação do cotovelo (sinergista); estabiliza o cotovelo durante a flexão e a extensão rápidas
		Extensor radial longo do carpo	Estende a mão junto com o extensor ulnar do carpo e abduz a mão junto com o flexor radial do carpo
		Extensor radial curto do carpo	Estende e abduz a mão; age sinergicamente com o extensor radial longo do carpo para estabilizar o carpo durante a flexão dos dedos
		Extensor comum dos dedos	Ajuda o agonista na extensão dos dedos; estende a mão; pode abduzir (afastar uns dos outros) os dedos
		Extensor do dedo mínimo	Estende o 5º dedo
		Extensor ulnar do carpo	Estende a mão junto com o extensor radial do carpo e aduz a mão junto com o flexor ulnar do carpo
		Supinador	Ajuda o bíceps braquial a realizar a supinação ³ forçada do antebraço; trabalha sozinho na supinação lenta; antagonista dos músculos pronadores
		Extensores longo e curto do polegar	Estendem o polegar

¹ A adução é o movimento oposto da abdução.

² Músculo que tem a responsabilidade principal por um determinado movimento (motor principal).

³ Rotação do antebraço de modo que a superfície anterior fique para fora, relativamente à posição anatómica.

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

Grupo	Camada	Músculo	Ação
		Extensor do dedo indicador	Estende o dedo indicador (2º dedo) e auxilia na extensão da mão
		Abdutor longo do polegar	Abduz e estende o polegar

Fonte: Marieb et al. (2014, p. 319-324).

Os 19 músculos do antebraço permitem mover a mão e o carpo, os dedos das mãos e alguns auxiliam na supinação e pronação do antebraço. O ventre da maioria desses músculos é proximal (ao cotovelo), distante do local de ação, e os tendões finos e longos são distais, com inserção na mão. Esta disposição minimiza o volume da região distal do antebraço, carpo e mão e permite máxima funcionalidade (Moore et al., 2017). A Tabela 2.2 resume as ações dos músculos do antebraço.

Tabela 2.2 – Resumo das ações dos músculos do antebraço.

		Ações no Carpo				Ações nos Dedos	
		Flexão	Extensão	Abdução	Adução	Flexão	Extensão
Compartimento Anterior	Flexor radial do carpo	X (MP)		X			
	Palmar longo	X (fraca)					
	Flexor ulnar do carpo	X (MP)			X		
	Flexor superficial dos dedos	X (MP)				X	
	Flexor longo do polegar					X (do polegar)	
	Flexor profundo dos dedos	X				X	
Compartimento Posterior	Extensor radial do carpo, longo e curto		X	X			
	Extensor comum dos dedos		X (MP)			X (e abdução)	
	Extensor ulnar do carpo	X		X			
	Abdutor longo do polegar			X		(abduz o polegar)	
	Extensores do polegar, longo e curto					X (do polegar)	
	Extensor do dedo mínimo					X (do 5º dedo)	
	Extensor do indicador		X (fraca)			X (do indicador)	

Fonte: Marieb et al. (2014, p. 288).

Nota: MP é abreviatura de “Motor Primário”. Os músculos motores primários, ou agonistas primários, são os principais responsáveis por executar um movimento específico.

2.2 Movimentos da mão

Nas articulações do carpo, os músculos do antebraço executam a flexão, extensão, abdução e adução da mão, mas nas articulações interfalângicas esses músculos apenas flexionam e estendem os dedos (Marieb et al., 2014). Os movimentos precisos dos dedos são realizados por pequenos músculos intrínsecos da mão. Esses movimentos incluem, para além da abdução e da adução, a oponência do polegar e do 5º dedo, o dedo mínimo (Figura 2.1).

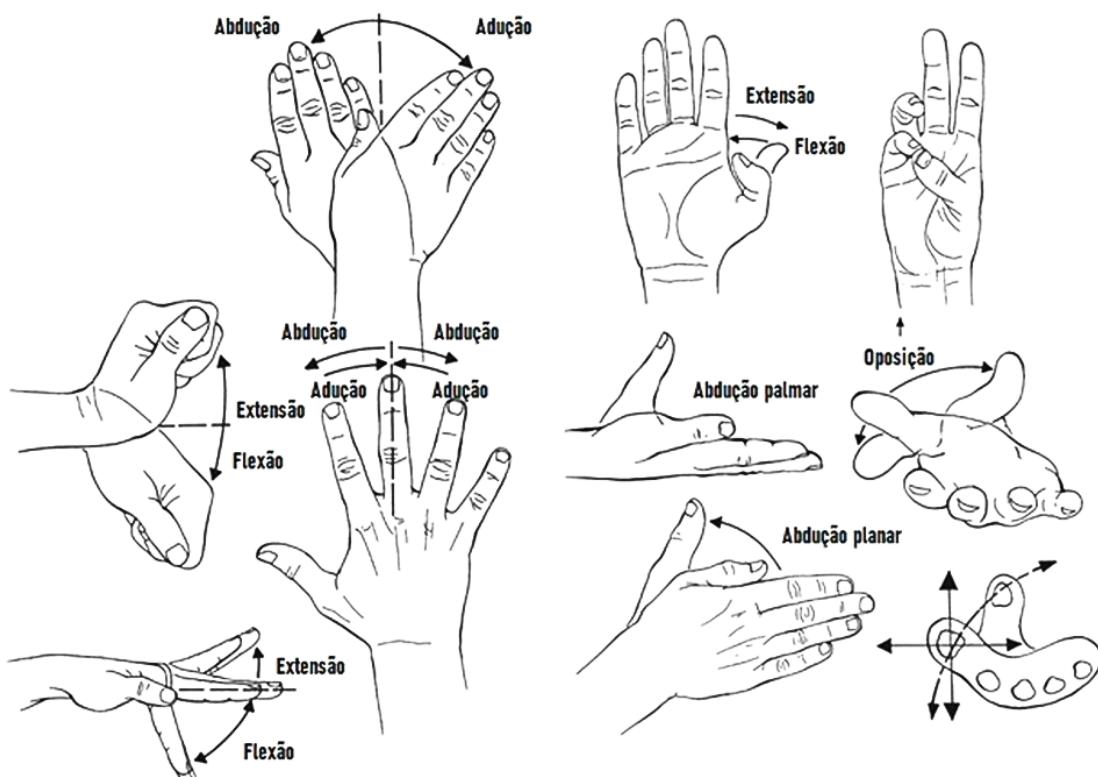


Figura 2.1 – Terminologia dos movimentos da mão (carpo) e dedos.

Fonte: Adaptado de (Seiler III, 2002).

De forma genérica e sintética, a flexão move uma parte do corpo numa direção anterior relativamente ao plano frontal da posição anatómica de referência, neutra. A extensão corresponde ao movimento na direção oposta. A articulação do joelho é a exceção onde tal não acontece. A abdução (que significa retirar) e a adução (reunir) são movimentos que, respetivamente, afastam e aproximam da linha mediana. A oponência é um movimento especial que não encaixa em nenhuma das outras categorias e que é exclusivo (Seeley et al., 2005) do polegar e do dedo mínimo. Acontece quando o polegar e o dedo mínimo se aproximam um do outro sobre a palma da mão.

Os gestos da mão são, portanto, combinações dos movimentos previamente explicados e da ação de diferentes músculos. A Tabela 2.3 apresenta alguns gestos com relevância para este estudo por envolverem músculos extrínsecos da mão.

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

Tabela 2.3 – Exemplos de gestos envolvendo músculos extrínsecos da mão.

	Fecho	Abertura	Point	3-Point pinch ⁽¹⁾⁽²⁾	Thumbs- up	Flexão	Extensão
Flexor radial do carpo						X	
Flexor ulnar do carpo						X	
Flexor superficial dos dedos	X		X	X	X	X	
Flexor profundo dos dedos	X		X	X	X	X	
Flexor longo do polegar	X		X				
Extensor radial do carpo, longo e curto							X
Extensor ulnar do carpo							X
Extensor comum dos dedos		X		X			X
Extensor longo do polegar		X		X	X		
Extensor curto do polegar		X			X		
Abdutor longo do polegar	X			X	X		
Extensor do indicador		X		X			X
Extensor do dedo mínimo		X					

Notas: ⁽¹⁾ “No *pinch*, a compressão é devida principalmente aos músculos extrínsecos” (Long et al., 1970). ⁽²⁾ “Testes estatísticos indicam que o tipo de *pinch* provoca um nível de participação significativamente diferente do flexor superficial dos dedos, mas não do flexor profundo dos dedos ou do extensor dos dedos, que contraem de maneira similar para os três *pinches* estudados” (Follows, 1987).

2.3 Eletromiografia (EMG)

2.3.1 Sinal mioelétrico

As fibras dos músculos estriados esqueléticos (de contração voluntária) são ativadas por impulsos nervosos¹, também chamados de potenciais de ação (Marieb et al., 2014), vindos do sistema nervoso central. O sinal mioelétrico é proveniente do potencial de ação que percorre a fibra muscular levando-a à contração (Ortolan, 2002). O bloco funcional básico do sistema neuromuscular é a unidade motora, formada por um neurônio motor e pelas fibras musculares que inerva.

¹ Despolarização transitória, incluindo reversão de polaridade, a qual é conduzida ao longo da membrana plasmática de um axônio ou célula muscular sem diminuir de intensidade.

Um potencial de ação no neurónio motor gera um potencial de ação em cada uma das fibras musculares da sua unidade motora (VanPutte et al., 2016, p. 285) que causa a sua contração simultânea. No entanto, nem todas as unidades motoras são idênticas. Ainda segundo VanPutte et al. (2016), elas variam em termos de quantidade de fibras musculares que contêm e em termos de sua sensibilidade ao estímulo para contração; algumas respondem prontamente a estímulos fracos, enquanto outras respondem somente a estímulos fortes. O número de fibras varia de acordo com o tamanho e a função do músculo (Moore et al., 2017). As grandes unidades motoras, nas quais um neurónio supre várias centenas de fibras musculares, estão nos grandes músculos do tronco e da coxa. Nos pequenos músculos dos olhos ou mãos, onde são necessários movimentos de precisão, as unidades motoras incluem apenas algumas fibras.

A adição de unidades motoras para obter um movimento chama-se recrutamento (Marieb et al., 2014, p. 263). Envolve aumentar a quantidade de fibras musculares que contraem e permite aumentar a força de contração. Ou seja, quando pouca força é exigida para determinado movimento, poucas unidades motoras são estimuladas; já em caso de muita força, outras unidades motoras são recrutadas.

Um músculo é constituído por múltiplas unidades motoras. A ativação (disparo) de uma unidade motora gera um MUAP (do inglês Motor Unit Action Potential) que é a soma das contribuições de cada uma das fibras individuais (Merletti, 2012). O sinal eletromiográfico (EMG) adquirido (Figura 2.2) é um sinal biomédico que corresponde ao somatório de todos os potenciais de ação das MUAPs detetados na área de alcance dos elétrodos utilizados, sendo por isso muito difícil fazer corresponder esse sinal a um músculo específico. Pode ser detetado por sensores colocados na superfície da pele (EMG de superfície, sEMG) ou usando elétrodos intramusculares tipo agulha.

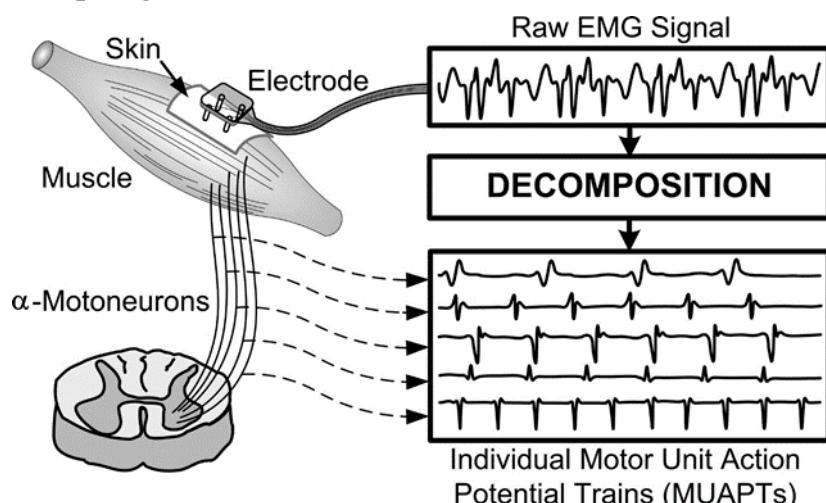


Figura 2.2 – O sinal sEMG corresponde ao somatório dos trens de potenciais de ação das unidades motoras detetados na área de alcance dos elétrodos.

Fonte: (de Luca et al., 2006).

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

A medida quantitativa dos parâmetros de MUAPs isoladas é de interesse em EMG por fornecer informações relevantes acerca da função neuromuscular. No entanto, a decomposição do sinal EMG não é trivial (de Luca et al., 2006).

2.3.2 Características do sinal EMG

O sinal EMG de cada músculo é dado pela soma dos vários trens de potenciais de ação das unidades motoras ativadas nas redondezas dos elétrodos, que apresentam características diferentes entre si. Além disso, uma ativação muscular pode envolver mais do que um músculo. Por estas razões, a amplitude do sinal EMG é descrita como estocástica (aleatória) por natureza e é comumente aceite que fica razoavelmente bem representada por uma distribuição de Gauss (Figura 2.3). Isto implica que a amplitude instantânea do sinal EMG é uma variável aleatória com média zero (Hudgins et al., 1993).

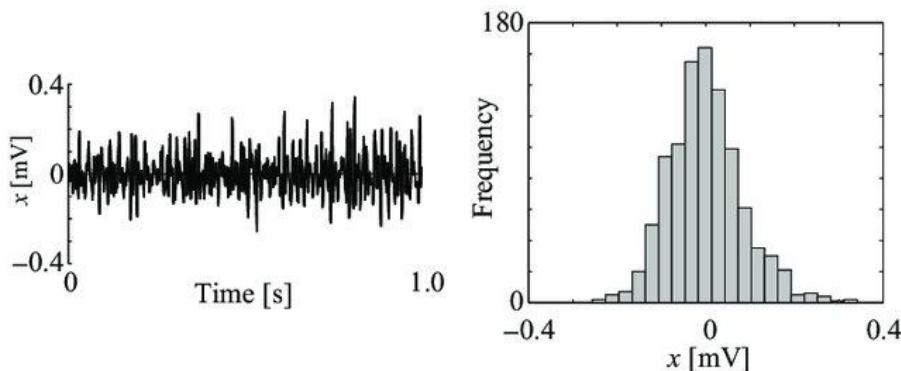


Figura 2.3 – Exemplo de sinal EMG bruto e histograma de amplitudes. Este sinal obedece a uma distribuição Gaussiana com média de 0 [mV].

Fonte: Adaptado de (Hayashi et al., 2021).

A amplitude do sinal EMG é influenciada pela força exercida na contração do músculo e insere-se no intervalo de 0-10 mV pico-a-pico, ou 0-1,5 mV RMS (valor eficaz). O sinal EMG obtido através de elétrodos de superfície é afetado pelas propriedades de filtro das camadas epiteliais e da interface elétrodo-pele; é útil, isto é, tem energia superior ao nível de ruído elétrico, para frequências dos <500 Hz, com a energia dominante no intervalo 50-150 Hz (De Luca, 2002). Na Figura 2.4 são apresentados exemplos de espectros de potência de sinais EMG detetados em diferentes gestos da mão.

Os sinais EMG possuem amplitudes na ordem dos mV e são bastante sensíveis a ruído elétrico. Ainda assim, como a largura de banda é superior nos sinais EMG comparativamente a outros biopotenciais, o problema dos artefactos de movimento e outras interferências tem menor relevância no sinal EMG (Thakor, 2014, p. 64-11).

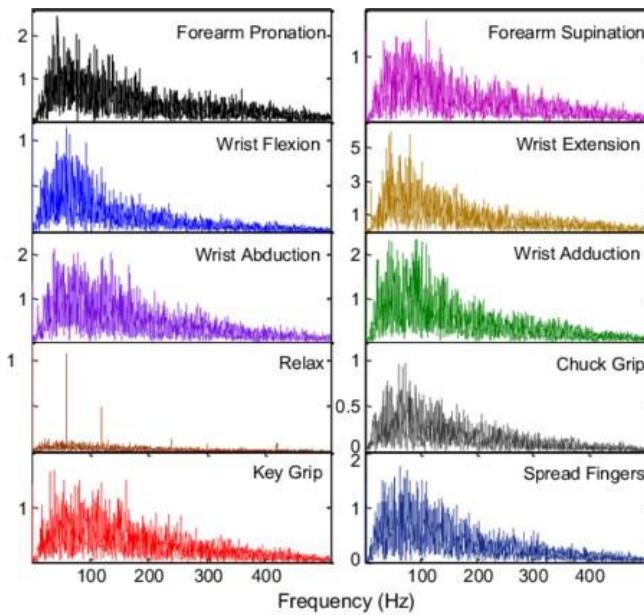


Figura 2.4 – Espectros de potência de sinais sEMG em gestos da mão, em dB.

Fonte: Rafiee et al. (2011).

Nota: A transformação em dB é geralmente calculada como $10 * \log_{10}(\text{PSD})$, onde o PSD está em $(\text{mV})^2/\text{Hz}$.

2.3.3 Aquisição do Sinal sEMG

A atividade mioelétrica é percebida à superfície da pele como potenciais elétricos de frequência na faixa dos 15-400 Hz, e de amplitude muita pequena, de alguns μV a poucos mV pico a pico, dependendo da intensidade da contração muscular (Cavalcanti Garcia & Vieira, 2011). Instrumentação muito sensível é, portanto, essencial para a deteção, condicionamento, amostragem temporal, e conversão Analógico/Digital (A/D) do sinal, de acordo com a Figura 2.5.

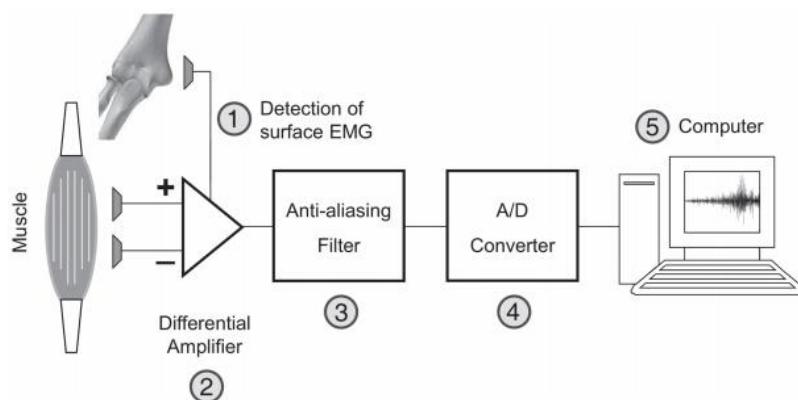


Figura 2.5 – Etapas da aquisição de sEMG: (1) deteção dos potenciais com elétrodos de superfície e um elétrodo de referência; (2) amplificação desses potenciais com amplificadores diferenciais; (3) filtragem analógica para evitar aliasing; (4) amostragem temporal e conversão A/D do sinal EMG e (5) posterior transmissão para computador.

Fonte: Cavalcanti Garcia e Vieira (2011).

2.3.3.1 Elétrodos e Interface Eléktodo-Pele

Os biopotenciais gerados aquando da contração e relaxamento musculares podem ser detetados por meio de elétrodos EMG. Existem dois tipos principais de elétrodos: os intramusculares (método invasivo) e os de superfície (método não-invasivo). O método invasivo envolve a inserção de agulhas (ou fios de arame extremamente finos) diretamente no músculo de interesse, através da pele. Estes elétrodos, quando comparados com elétrodos não-invasivos, captam maiores amplitudes e espectros de potência mais amplos, com frequências até 10 kHz (Ortolan, 2002). Este método apresenta duas vantagens principais: (i) as leituras são pouco afetadas pelos potenciais elétricos gerados em músculos próximos e (ii) permite medir atividades elétricas musculares de músculos profundos. No entanto, os vários níveis de desconforto que pode infligir no paciente e a certificação médica exigida faz com que a sua utilização se restrinja a procedimentos clínicos, nomeadamente na avaliação da função neuromuscular. Ao contrário dos elétrodos intramusculares, os elétrodos de superfície são simples, fáceis de implementar e possibilitam a aquisição não-invasiva de sinais EMG. A sEMG mede a atividade elétrica muscular e é vastamente usada em investigação, mas, ao contrário de outros sinais eletrofisiológicos ainda não transitou com sucesso para a prática clínica (McManus et al., 2020). É uma técnica conveniente apesar de produzir uma informação grosseira sobre o músculo em investigação, pois deteta a atividade elétrica de todo um grupo muscular (Ortolan, 2002). Este facto faz com que seja difícil monitorizar com precisão músculos de camadas mais profundas relativamente a outros e que fazem ações semelhantes (pertencentes ao mesmo grupo muscular). Por outro lado, a amplitude dos sinais mioelétricos deve ser suficiente para que o sinal EMG de superfície possa ser detetado e separado do ruído de fundo. A gordura subcutânea tem um impacto negativo tanto na amplitude no sinal EMG de superfície como no *crosstalk*¹ (Kuiken et al., 2003). Como referido anteriormente, os elétrodos de superfície são capazes de captar sinais até ~500 Hz, com amplitudes de pico de ~5 mV.

Existem dois tipos de elétrodos de superfície (Day, 2002) que são normalmente usados: (i) os elétrodos secos em contacto direto com a pele e (ii) os elétrodos húmidos (ou passivos), que possuem um gel eletrolítico como interface químico entre a pele e a parte metálica do elétrodo. Prata - cloreto de prata (Ag-AgCl) é o compósito mais comum da parte metálica dos elétrodos húmidos. A camada de AgCl permite melhorar a condução de corrente do músculo na interface eletrólito-elétrodo. Isto introduz menos ruído elétrico nas medidas, em comparação com os elétrodos metálicos (Duchêne et Goubel, 1993). Os elétrodos secos são normalmente mais pesados (>20 g) que os húmidos (<1 g) (Jamal, 2012).

¹ Termo usado em sEMG para o sinal EMG detetado sobre um músculo de interesse, mas produzido por outro músculo próximo.

Os elétrodos EMG são tipicamente ligados numa configuração bipolar; são usados dois elétrodos ativos para captação de sinal, para além de um elétrodo de referência. Os sinais detetados pelos elétrodos colocados sobre o ventre muscular são subtraídos um ao outro e a diferença é amplificada. Como resultado, qualquer sinal que tenha origem longe do local de deteção e que constitui o sinal “comum” (De Luca, 2002) – como são os ruídos de 50 Hz oriundos da rede elétrica – é atenuado. O elétrodo de referência é necessário para fornecer um potencial de referência comum para o circuito pré-amplificador.

A pele deve ser limpa com álcool etílico e pode ser necessária a tricotomia da região antes da colocação dos elétrodos, na tentativa de reduzir a impedância elétrodo-pele e melhorar a estabilidade da fixação. O uso do gel eletrolítico não é recomendado se os artefactos de movimento forem uma preocupação (de Luca, 2008).

A qualidade do sinal EMG é influenciada em grande medida pelo posicionamento dos elétrodos. É importante ter em conta os seguintes aspectos:

- i. Localização e orientação dos elétrodos ativos: os elétrodos devem ser colocados na linha média do músculo, a cerca de 20 mm de zonas de inervação¹ (Kamen & Gabriel, 2010) e entre a zona de inervação e o local de inserção do tendão (ou entre zonas de inervação (De Luca, 2002)). Os elétrodos devem ser alinhados paralelamente à direção longitudinal das fibras musculares.
- ii. Distância entre os elétrodos ativos: se for mantida uma distância interelétrodos fixa, a largura de banda do sinal sEMG permanece constante (de Luca, 2008). Este autor recomenda uma distância interelétrodos de 1 cm, sendo que a amplitude do sinal é diretamente proporcional à distância interelétrodos e a largura de banda é inversamente proporcional. Para Kamen & Gabriel (2010), a distância pode variar entre 0,5 e 2 cm dependendo do tamanho do músculo.
- iii. Elétrodo de referência: deve ser colocado o mais longe possível, num tecido eletricamente neutro (como uma proeminência óssea, tipicamente o punho ou cotovelo). É importante assegurar um muito bom contato elétrico entre o elétrodo e a pele; deve usar-se um elétrodo grande (2 cm x 2 cm). Uma colocação criteriosa do elétrodo de referência contribui para a redução do ruído de 50 Hz da rede (De Luca, 2002).

2.3.3.2 Condicionamento do Sinal EMG Bruto

O condicionamento do sinal EMG consiste na adequação deste por meio de amplificação e filtragem. A amostragem e conversão A/D do sinal requer amplificação do sinal para valores da ordem dos Volt. Tipicamente, a gama dinâmica dos conversores A/D em EMG varia de 2,5-10 V (Cavalcanti Garcia & Vieira, 2011).

¹ Regiões no músculo esquelético onde as terminações dos neurónios motores α e as fibras musculares se ligam através de sinapses especiais chamadas junções neuromusculares.

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

Os amplificadores usados devem ter uma alta impedância de entrada ($> M\Omega$), bem como uma elevada razão de rejeição de modo comum (CMRR, na sigla em inglês). A filtragem analógica é necessária para remover os ruídos de alta frequência (> 500 Hz) e os artefactos de movimento (< 20 Hz). A remoção de componentes indesejadas do sinal sEMG também pode ser feita depois da sua digitalização, através de filtros digitais (Cavalcanti Garcia & Vieira, 2011). O bloco de condicionamento do sinal EMG é um circuito analógico que tem três funções principais (Merletti & Cerone, 2020):

- i. Amplificar o sinal EMG bruto de forma a adaptar a amplitude do sinal à do sistema conversor A/D;
- ii. Eliminar as harmónicas (componentes de frequência) fora da banda de frequências do sEMG;
- iii. Rejeitar o ruído de modo comum e artefactos na banda de frequências do sinal.

2.3.3.3 Amostragem e Conversão A/D

O sinal sEMG é analógico (de natureza contínua no tempo) e, como tal, para poder ser armazenado e processado por computador, precisa de ser amostrado e cada amostra convertida para formato digital (Merletti & Cerone, 2020).

Um sinal pode ser representado como o somatório de sinusoides de diferentes amplitudes. O teorema de Nyquist define a frequência mínima de amostragem para evitar perda de informação devida ao processo de amostragem como o dobro da componente de frequência mais alta do sinal. Se este critério for satisfeito, é possível reconstruir o sinal analógico original a partir do sinal digital (Merletti & Cerone, 2020). Quando os sinais analógicos são amostrados a frequências inferiores (no caso do sinal sEMG, menos de 1000 amostras/segundo), sinusoides com frequências acima desse *threshold* sobrepõem-se às sinusoides de frequências mais baixas. Este fenômeno é conhecido como *aliasing* (Cavalcanti Garcia & Vieira, 2011). É evidente que quanto maior a frequência de amostragem (acima da frequência de Nyquist), mais fidedigna é a representação digital do sinal. A banda de frequências dos sinais sEMG estende-se até 450-500 Hz e tipicamente, na prática, usam-se frequências de amostragem de cerca de 2000 amostras/s (Merletti & Cerone, 2020), ou 4/ciclo.

2.3.4 Processamento do Sinal EMG

O sinal EMG bruto fornece informações valiosas numa forma particularmente inútil. Esta informação só é útil se puder ser quantificada (Raez et al., 2006). Nesse sentido, várias técnicas matemáticas de processamento de sinal podem ser aplicadas ao sinal EMG bruto com vista à extração de informação relevante para análises posteriores. Na abordagem típica em sistemas de reconhecimento de padrões em sEMG são comuns as etapas: (i) segmentação dos dados, (ii) extração de características e (iii) classificação (Oskoei & Hu, 2008; Silva, 2018; Simão et al., 2019).

O processo de segmentação consiste na separação dos intervalos para a extração de características. Uma das formas mais comuns de segmentação dos dados envolve a determinação do *onset* e do *offset* (Figura 2.6) do sinal EMG (Freitas, 2018), onde o *onset* equivale ao momento onde se inicia algum movimento dentro da aquisição dos dados (normalmente envolvendo contração muscular) e o *offset* se refere ao momento onde este movimento termina.

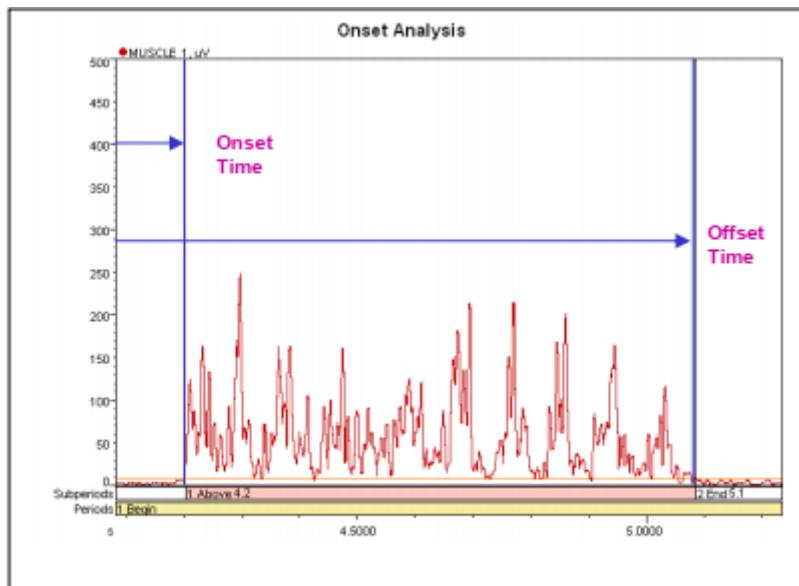


Figura 2.6 – Ilustração dos tempos de *onset* e *offset* do sinal EMG.

Fonte: Konrad (2005).

O processo de extração de características é definido como o método para extrair informação útil que está contida no sinal EMG (Phinyomark et al., 2012, citado por Sarmiento Vela, 2013), eliminando as partes indesejadas e ruído.

Segundo (De Luca, 2002), na viragem do século, o processamento do sinal EMG resumia-se ao cálculo do Integral do Valor Absoluto (IAV), do Valor Médio Absoluto (MAV) e do Valor Eficaz (RMS). Estas medidas, do domínio do tempo, eram priorizadas pela facilidade de cálculo e eficiência computacional.

Nos dias de hoje, são utilizadas e estudadas mais de 50 características, distribuídas principalmente por três domínios: o tempo, a frequência, e o tempo-frequência (Phinyomark et al., 2012; Freitas, 2018). As características no domínio do tempo são normalmente preferidas em reconhecimentos de padrões baseados em sEMG (Christopher et al., 2018); são fáceis e rápidas de calcular dado não precisarem de transformação prévia do sinal (menos gasto computacional). São calculadas tendo por base a amplitude do sinal EMG.

Depois de extraídas as características desejadas do sinal EMG *bruto*, busca-se fazer o reconhecimento de padrões com relação a gestos ou movimentos realizados durante a aquisição de sinal (Freitas, 2018) através de um dos vários tipos de classificadores existentes (Christopher et al., 2018; Freitas, 2018; Simão et al., 2019).

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

O MATLAB (The MathWorks Inc.) e o LabVIEW (National Instruments Corp) são os ambientes mais utilizados para análise e tratamento de sinais.

2.3.5 Características do Ruído em sEMG

Os sinais bioelétricos, onde o sinal sEMG se enquadra, são inevitavelmente contaminados por ruído e apresentam uma fraca relação sinal-ruído¹. Em geral, ruído é qualquer informação indesejada contida num sinal (Florimond, 2010). O ruído pode ser categorizado nos seguintes tipos:

- i. Ruído ambiente: é a fonte de ruído mais comum; inclui qualquer fonte de radiação eletromagnética sendo que a maior preocupação é a interferência da rede elétrica (50 Hz). Pode ter uma amplitude uma a três ordens de magnitude superior à amplitude do sinal EMG (De Luca, 2002). Este ruído pode ser removido por detecção diferencial (configuração bipolar) (de Luca, 2008) e um filtro rejeita-banda (*notch*) pode ser aplicado para atenuar a componente de 50 Hz do sinal (Florimond, 2010).
- ii. Artefactos de movimento: o comprimento de um músculo diminui quando é ativado. Além disso, existe um movimento relativo entre músculo, pele e elétrodos (Nazmi et al., 2016). Surgem na interface pele-eléktodo ou nos cabos que conectam os elétrodos ao restante equipamento. Possuem a maior parte da sua energia na faixa dos 0-20 Hz e uma amplitude comparável à do sinal EMG (Nazmi et al., 2016). O movimento indesejado dos elétrodos pode ser evitado escolhendo o tipo de elétrodos certo e fixando-os firmemente à pele. Pode aplicar-se um filtro passa-alto a 20 Hz ao sinal (Florimond, 2010).
- iii. Ruído ECG: o sinal ECG tem origem no coração e pode contaminar o sinal EMG. A colocação dos três elétrodos no mesmo lado do coração reduz estes artefactos (Florimond, 2010). Existem outros tecidos que podem gerar ruídos fisiológicos como os músculos respiratórios e o olho (sinal EOG) (de Luca, 2008).
- iv. Ruído de DC *offset* (ou de *baseline*): é causado pela diferença na impedância entre a pele e os elétrodos (Florimond, 2010) e pela excitação térmica de eletrões livres nos condutores, no estágio inicial dos amplificadores (de Luca, 2008). Acrescenta uma componente DC ao sinal EMG. O ruído de *baseline* pode ser substancialmente reduzido por uma preparação adequada da pele sob o sensor sEMG e pela escolha de componentes de qualidade.
- v. Ruído inerente do próprio equipamento EMG: todos os dispositivos eletrónicos geram ruído elétrico. Este tipo de ruído não pode ser eliminado; pode apenas ser minimizado usando componentes eletrónicos de alta qualidade e de um design inteligente dos circuitos. Pode ter componentes de frequência de 0 a vários kHz (De Luca, 2002).

¹ Razão entre a energia no sinal EMG e a energia do sinal de ruído elétrico.

2.4 Force Myography (FMG)

2.4.1 Fundamentos e aplicações em próteses biônicas

O termo FMG, ou miografia de força, descreve as várias técnicas não-invasivas que usam sensores de força para detetar mudanças voluntárias associadas à ativação/desativação dos grupos musculares superficiais relativamente a um estado de *default* que normalmente corresponde ao membro em posição relaxada (Grushko et al., 2020). Permite também detetar as mudanças voluntárias causadas pelo movimento dos tendões sob a superfície da pele (por exemplo no pulso (McIntosh et al., 2016)).

O primeiro trabalho sobre a técnica FMG como modalidade de controlo de próteses mioelétricas foi publicado em 1999 (Abboudi et al., 1999) mas apenas em meados da última década ganhou tração entre os investigadores, impulsionada pelo desenvolvimento das técnicas de Machine Learning.

Várias publicações científicas (Citi et al., 2016; Kadkhodayan et al., 2016; Radmand et al., 2016) apresentam resultados promissores sobre a possibilidade de usar a técnica FMG na predição da intenção de movimento em implementações de próteses biônicas de mão. Mais recentemente, existe um interesse crescente em combinar sEMG e FMG de forma a criar sistemas de controlo mais robustos para serem utilizados por modelos de reconhecimento de padrões (Jaquier et al., 2017; Nowak et al., 2017; Xiao & Menon, 2017). O que torna o sistema bimodal interessante é o facto de detetar ambos os fenómenos elétrico e volumétrico associados à contração muscular. Em 2020, Jiang et al. propôs uma abordagem co-localizada para adquirir EMG e FMG simultaneamente na mesma localização, conseguindo um aumento de 10% de exatidão na identificação de 10 sinais de linguagem gestual americana, relativamente às modalidades isoladas.

Em geral, a robustez e/ou exatidão aumentam quando usados sistemas multimodais de aquisição. Contudo, também aumenta o processamento de informação necessário, e a complexidade de integrar todos os sensores no mesmo sistema híbrido de aquisição.

É também expectável que em sistemas FMG unimodais, o número de sensores influencie fortemente a exatidão dado que possibilitam uma resolução espacial mais elevada e a extração de um maior número de características (Grushko et al., 2020). No entanto, existem ainda várias insuficiências (Xiao & Menon, 2017, 2019) que precisam de ser debeladas de forma a poder utilizar a tecnologia FMG em próteses biônicas comerciais.

2.4.2 Aquisição de sinais FMG

2.4.2.1 Sensores FMG

Os sensores de força utilizados na FMG registam mudanças de pressão devidas a alterações na morfologia dos músculos superficiais. A tecnologia PTF (de Polymer Thick Film), que inclui os sensores FSRTM da Interlink Electronics® e os sensores FlexiforceTM da TekscanTM, são comumente usados. Apesar das suas vantagens, como serem acessíveis, compactos e leves, apresentam limitações na exatidão (apesar da sensibilidade) e repetibilidade das medições de pressão absoluta (Esposito et al., 2018). Embora permitam medições dinâmicas, apenas resultados qualitativos são geralmente extraíveis.

2.4.2.2 Condicionamento do sinal

O circuito de condicionamento de sinal de um sensor FSRTM pode ser simplesmente um divisor de tensão, alimentado pela tensão fornecida por um microcontrolador (Figura 2.7). Contudo, esta configuração pode causar degradação da sensibilidade e exatidão do sensor. Para reduzir a não-linearidade da resposta do sensor, utiliza-se um circuito conversor corrente-tensão que mantém a tensão no sensor constante (Esposito et al., 2018). Em aplicações FMG para identificação de gestos, contudo, em que a gama de forças aplicadas é estreita, a linearidade do sinal desempenha um papel menos relevante.

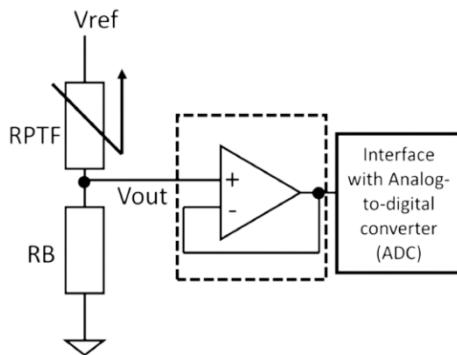


Figura 2.7 – Circuito divisor de tensão seguido de *buffer*.

Fonte: Retirado de Xiao e Menon (2019).

O número de sensores usados varia dependendo da aplicação, com algumas a usar matrizes personalizadas com um grande número de sensores para mapear todo o antebraço (Castellini et al., 2018; Radmand et al., 2014).

2.4.3 Processamento de sinais FMG

A maioria dos trabalhos FMG adota uma abordagem clássica de Supervised Machine Learning para prever os gestos. Este abordagem requer uma etapa preliminar de recolha de dados, onde se extraem características relevantes associadas aos gestos

estudados, para alimentar um modelo de decisão entretanto desenvolvido. A supervisão surge pela necessidade de intervenção humana, tanto na rotulagem (*labeling*) das amostras como na seleção das características a extrair.

Existem duas categorias de algoritmos de Machine Learning: os de classificação e os de regressão. Os modelos de classificação são usados na predição de estados discretos (classes) como gestos da mão enquanto os modelos de regressão permitem identificar estados contínuos como força de preensão ou movimentos de dedos. Pela necessidade de reconhecer gestos da mão, optámos por utilizar vários modelos de classificação neste trabalho.

O objetivo da classificação é, a partir de um vetor de entrada como o sinal FMG e/ou sEMG, ou das suas características extraídas, atribuir-lhe uma label - neste caso, abertura, fecho, apontar, *pinch*, ou *thumbs-up*. Os classificadores Fisher's Linear Discriminant Analysis, Support Vector Machines (SVMs) e Artificial Neural Networks são os mais frequentemente usados na literatura FMG (Xiao & Menon, 2019).

2.5 Introdução à Classificação em Reconhecimento de Padrões

Este subcapítulo introduz a relevância da classificação em reconhecimento de padrões. A classificação em reconhecimento de padrões é um elemento integral de Machine Learning e da inteligência artificial, com uma ampla gama de aplicações em várias disciplinas, nomeadamente a visão computacional, o processamento de linguagem natural, a bioinformática e, de forma mais pertinente para o nosso contexto, o controlo de próteses mioelétricas. A classificação aborda a tarefa de atribuir labels a entidades ou classes com base em características identificáveis. No contexto das próteses mioelétricas, isto poderia envolver a categorização de sinais mioelétricos provenientes dos músculos residuais do antebraço, associando-os a ações pretendidas, como a intenção de "fechar a mão".

A escolha do algoritmo de classificação é altamente dependente da natureza do problema e das características dos dados (Wikipedia contributors, 2023c). Classificadores lineares são frequentemente utilizados quando as classes são linearmente separáveis, enquanto os classificadores não lineares, como as Redes Neurais ou SVM, podem ser necessários para situações mais complexas. A avaliação do desempenho do classificador é realizada através de várias métricas, incluindo a precisão, a sensibilidade, a especificidade, o F-score e a área sob a curva ROC (*Receiver Operating Characteristic*). Cada uma dessas métricas oferece uma perspetiva única sobre a eficácia do classificador e juntas ajudam a construir uma imagem completa do seu desempenho.

2.6 Próteses biónicas de membro superior comerciais

A mão humana representa o culminar de milhões de anos de evolução, possuindo 21 graus de liberdade nos dedos e 6 no carpo, além da crucial capacidade de oposição do polegar. Esta estrutura complexa mantém uma comunicação bidirecional com o sistema nervoso periférico, permitindo controlo motor e fornecendo feedback sensorial (Cordella et al., 2016). A amputação é um evento que compromete significativamente a autonomia do indivíduo, restringindo a realização de tarefas diárias e profissionais, e impactando a vida social. Infelizmente, com a tecnologia de próteses atual, estas consequências são irreversíveis (Castellini, 2020; Cordella et al., 2016; Grushko et al., 2020).

No entanto, com os avanços recentes em tecnologia e engenharia, estão a surgir novas soluções que podem mudar a vida das pessoas que perderam um membro superior, como um braço ou uma mão. As próteses biónicas de membro superior, especificamente, representam uma tentativa de replicar a função e, em alguns casos, a aparência da mão humana. Incorporando sensores e elementos mecânicos controlados por sinais elétricos, esses dispositivos prometem devolver uma parte da autonomia perdida.

Várias empresas têm contribuído para este campo, com produtos comercialmente disponíveis que representam marcos importantes na tecnologia de próteses. É importante mencionar alguns exemplos notáveis:

- a. i-Limb (Touch Bionics, 2007): Esta mão biónica, desenvolvida pela empresa escocesa Touch Bionics, foi a primeira com cinco dedos articulados independentemente. Incorporando sensores mioelétricos, a i-Limb possibilita o controlo individual de cada dedo e a realização de diversos padrões de preensão. A prótese tem a capacidade de ajustar a força de preensão, permitindo ao utilizador realizar tarefas delicadas sem danificar objetos frágeis. Com uma construção robusta, pode ser coberta com uma luva cosmética para uma aparência mais natural (Figura 2.8).



Figura 2.8 – i-Limb da Touch Bionics (2009).

Fonte: Drew Halley (2009).

- b. Bebionic Hand (RSLSteeper, 2010): Concebida no Reino Unido e agora propriedade da Ottobock desde 2017, é uma prótese notável por ser a primeira com um pulso motorizado, proporcionando rotação de 135° e flexão/extensão de 35° (Aaron Saenz, 2010). Possui 14 padrões de preensão programáveis e a capacidade de se adaptar ao objeto que está a segurar. Além disso, inclui uma cobertura de silicone que simula a pele humana (Figura 2.9).



Figura 2.9 – Bebionic, introduzida pela RSLSteeper (2010).

Fonte: Adaptado de Belter et al. (2013).

- c. Michelangelo Hand (Ottobock, 2011): Esta prótese distingue-se por ser a primeira a integrar um polegar eletronicamente acionado, que reproduz fielmente os movimentos antropomórficos da mão humana (Wikipedia contributors, 2023a). O polegar pode também ser posicionado de forma passiva (“à mão”); nesta modalidade, o polegar permanece estável na posição escolhida até ser reajustado. Apesar de permitir apenas 7 padrões de preensão, é capaz de realizar tarefas delicadas, suportadas por um sistema de controlo eficiente com sensores EMG. Além disso, conta uma bateria que permite até 20 horas de autonomia entre cargas (Rodrigues, 2021). Para oferecer uma aparência mais natural, dispõe de luvas cosméticas em vários tons de pele (Figura 2.10).



Figura 2.10 – Michelangelo Hand (2011)

Fonte: Adaptado de Belter et al. (2013).

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

- d. DEKA Arm (DEKA, 2014): Inspirada pela mão robótica de Luke Skywalker em Star Wars, esta prótese trouxe inovações significativas. Começou por oferecer 12 dimensões distintas de movimento, aproximando-se muito da funcionalidade de um braço humano. O controlo da prótese era realizado por meio de sensores especiais (Inertial Measurement Units, ou IMUs) implantados no sapato do utilizador e sensores adicionais localizados nos músculos do coto do braço, que detetavam contrações musculares para comandos variados (Heath, 2014). Posteriormente, a prótese evoluiu para incorporar feedback sensorial por meio de sensores de força de preensão (Mobius Bionics LLC, 2019), proporcionando ao utilizador uma percepção de quão fortemente estão a segurar um objeto. Conta com três tipos diferentes - configurações radial, humeral e de ombro. O DEKA Arm (Figura 2.11), originalmente desenvolvido pela DEKA Research and Development Corporation, recebeu aprovação para uso comercial pelo FDA em 2014. Atualmente, é comercializado como LUKE Arm pela Mobius Bionics.



Figura 2.11 – DEKA/Luke Arm (em configuração humeral).

Fonte: Mobius Bionics LLC (2019).

- e. Hero Arm (Open Bionics, 2018): Criada pela start-up britânica Open Bionics, foi a primeira prótese biónica multi-grip impressa em 3D e com aprovação médica (Figura 2.12). Acessível e leve, esta prótese permite seis gestos de preensão distintos, rotação de pulso de 180° e proporciona feedback táctil através de vibrações.



Figura 2.12 – Hero Arm da Open Bionics.

Fonte: Open Bionics (sem data).

3 METODOLOGIA

3.1 Descrição da População e dos Gestos Estudados

Neste estudo, a população em análise é composta por três participantes não-amputados e saudáveis, desprovidos de quaisquer restrições físicas que pudesse interferir na execução dos gestos a serem estudados. Importa realçar que na seleção dos participantes, não foram considerados critérios de exclusão baseados em fatores demográficos como idade ou género, de forma a assegurar a abrangência dos resultados obtidos.

Os gestos de interesse analisados neste estudo, exibidos na Figura 3.1, são: abertura da mão, fecho da mão (em punho), *3-point pinch*, *thumbs-up* e apontar. A escolha destes gestos justifica-se pela sua importância nas atividades diárias e na comunicação interpessoal, e porque recrutam diferentes combinações de músculos do antebraço, produzindo padrões de sinais EMG e FMG distintos, o que permite a sua distinção através da análise de dados.

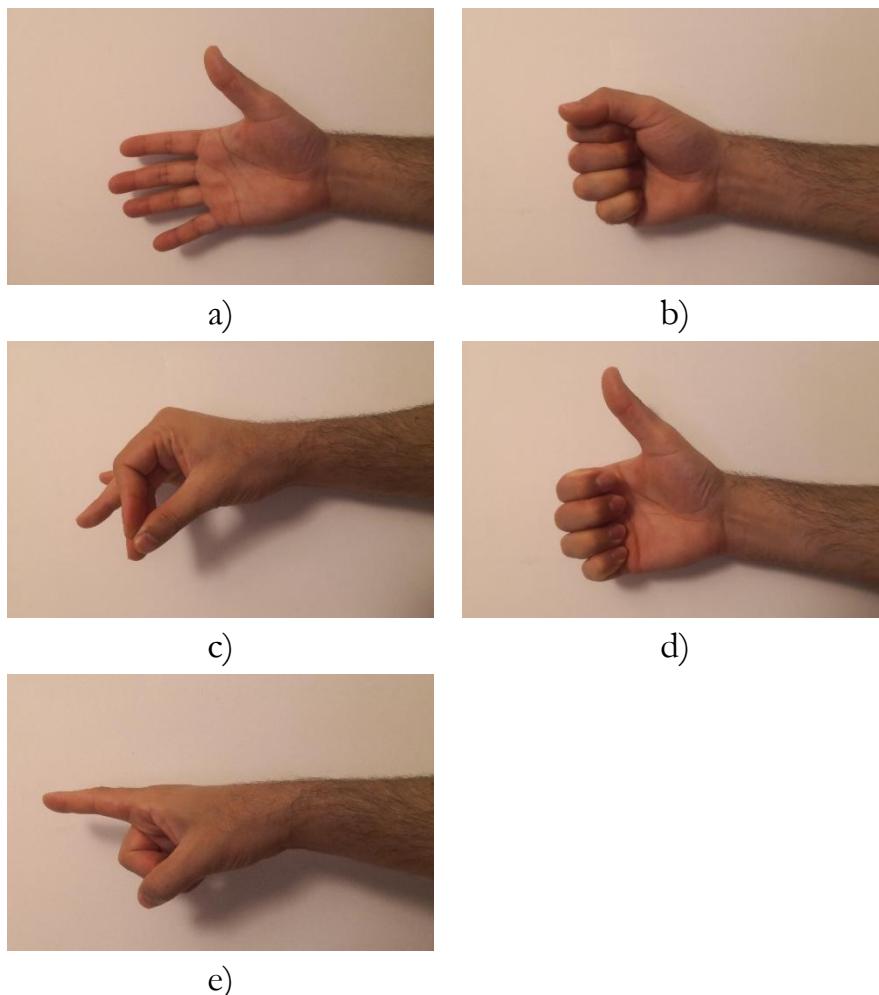


Figura 3.1 – Gestos utilizados para classificação: a) Abertura da mão; b) Fecho da mão (em punho); c) *3-point pinch*; d) *Thumbs-up*; e) Apontar.

3.2 Hardware e software

3.2.1 BITalino (r)evolution e OpenSignals

Para a aquisição de sinais fisiológicos neste projeto, recorreu-se ao BITalino (r)evolution (Figura 3.2), desenvolvido pela Plux Wireless Biosignals. Esta plataforma distingue-se pela capacidade de integrar uma ampla diversidade de sensores.

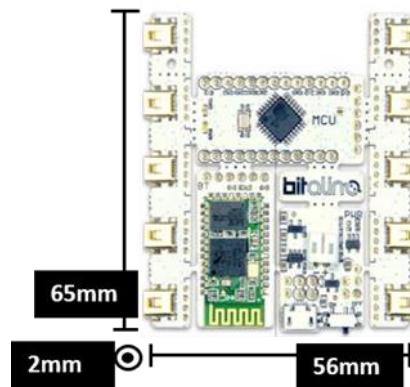


Figura 3.2 – BITalino (r)evolution Core BT.

Os sensores que podem ser conectados à placa BITalino incluem: eletromiografia (EMG), eletrocardiografia (ECG), acelerómetro (ACC), força (FSR), temperatura (TMP), luz (LUX), atividade eletrodérmica (EDA), eletroencefalografia (EEG), eletro-oculografia (EOG), eletrogastrografia (EGG), fotopletismografia (PPG) e saturação de oxigénio (SpO₂).

No contexto deste projeto, a placa BITalino foi utilizada para recolher sinais EMG e FMG. Os sinais EMG foram obtidos com recurso a 2 sensores EMG próprios do BITalino. Por outro lado, a captura dos sinais FMG exigiu a utilização de 2 sensores FSR 402 externos, que, após um circuito de condicionamento de sinal, foram integrados ao BITalino.

A Tabela 3.1 contém especificações técnicas do BITalino (r)evolution, com base no data sheet do dispositivo (PLUX Wireless Biosignals, 2016).

Tabela 3.1 – BITalino (r)evolution: especificações técnicas.

Taxa de amostragem	1, 10, 100 ou 1000 Hz
Portas analógicas	4 in (A1-A4, 10-bit) + 2 in (A5-A6, 6-bit) + 1 out (8-bit)
Portas digitais	2 in (1-bit) + 2 out (1-bit)
Conectividade	Bluetooth de Classe II v2.0 (alcance de até 10 m)
Tensão de Entrada	3,0-5,5 V
Bateria	700 mA 3,7 V LiPo (recarregável)
Consumo	~65 mA
Tamanho	65x56 mm
Peso	~30 g

A transmissão de dados para o computador é feita em tempo real via Bluetooth. Por sua vez, o software OpenSignals, compatível com a plataforma BITalino, permite a visualização em tempo real dos dados de múltiplos canais e dispositivos (até 24 canais e 3 dispositivos). Adicionalmente, o software possibilita a exportação dos dados nos formatos .txt e .h5, bem como a visualização offline dos mesmos (Figura 3.3).

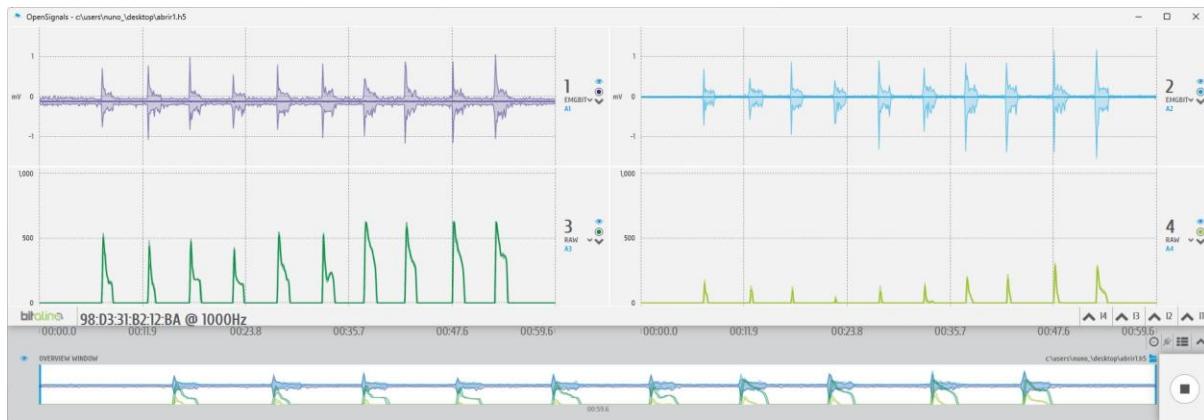


Figura 3.3 – Visualização no OpenSignals de um ficheiro de dados previamente armazenado, mostrando sinais EMG (em cima) e FMG (em baixo) para o gesto “abertura da mão”.

3.2.2 Sensor EMG

Conforme mencionado anteriormente, a monitorização da atividade elétrica dos grupos musculares flexor e extensor do antebraço fez-se com recurso a dois sensores EMG do BITalino, tais como aquele apresentado na Figura 3.4a.

Especialmente projetado para aquisições de sEMG, é compatível com elétrodos de gel e secos, e oferece dados de alta qualidade com baixo ruído devido à sua configuração bipolar (PLUX Wireless Biosignals, 2020).

O sensor EMG é responsável pela filtragem analógica, amplificação e conversão A/D do sinal.

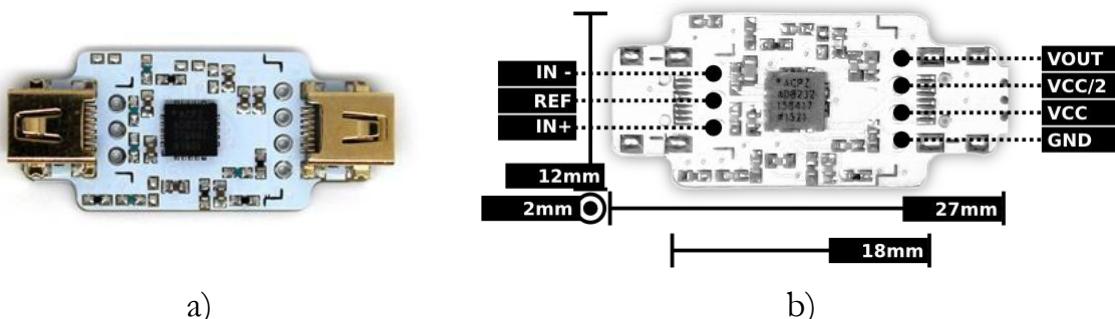


Figura 3.4 – Sensor EMG do BITalino: a) Versão com conexões UC-E6; b) Pin-out.

Fonte: PLUX Wireless Biosignals (2020).

A Tabela 3.2 apresenta as especificações técnicas do sensor EMG do BITalino.

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

Tabela 3.2 – Especificações técnicas do sensor EMG.

Ganho	1009
Gama	± 1.64 mV (com VCC = 3.3 V)
Largura de banda	25-480 Hz
Consumo	~ 0.17 mA
Gama de tensão de entrada	2.0-3.5 V
Impedância de entrada	7.5 G Ω
CMRR	86 dB

Fonte: PLUX Wireless Biosignals (2016b).

3.2.3 FSR 402

Os sensores FSR (Force-Sensing Resistors) são dispositivos passivos de dois terminais que alteram a resistência elétrica da sua camada de polímero condutor em função da força aplicada à sua superfície. Esta característica é explorada em diversas aplicações, desde o controlo táctil de dispositivos eletrónicos, sistemas automóveis e médicos, até aplicações em robótica e indústria.

No âmbito deste projeto, foram selecionados sensores do modelo FSR 402 (Figura 3.5). Dois destes sensores foram aplicados, um para cada grupo muscular em estudo: o flexor e o extensor do antebraço.



Figura 3.5 – Sensor FSR 402.

A escolha dos sensores FSR é justificada pela sua capacidade de detetar variações na força em relação a um estado inicial/de repouso, ao invés de fornecer uma medição precisa da força aplicada. Esta propriedade é essencial para sistemas de FMG no reconhecimento de gestos, onde o objetivo não é necessariamente quantificar a força exata que está a ser aplicada, mas identificar se há alguma força a ser aplicada e como essa força muda ao longo do tempo. O FSR 402, em particular, foi escolhido pela sua área ativa (14,7 mm de diâmetro) e força mínima de atuação (0,1 N), consideradas adequadas para a aplicação em questão.

Para a conversão simples de força para tensão, o FSR 402 é ligado em configuração de divisor de tensão. A tensão de saída, V_{OUT} , é dada pela equação seguinte:

$$V_{OUT} = \frac{R_M}{(R_M + R_{FSR})} V_+ \quad (3.1)$$

Na equação (3.1), R_M representa a resistência do potenciômetro, R_{FSR} é a resistência do sensor FSR e V_+ é a tensão de alimentação. Dependendo dos requisitos de impedância do circuito, o divisor de tensão pode ser seguido por um amplificador operacional, que funciona como *buffer*¹. Na configuração apresentada na Figura 3.6a, a tensão de saída aumenta com a força. Se o sensor e o potenciômetro forem invertidos, a tensão de saída diminuirá com o aumento da força.

A resistência R_M é ajustada para maximizar o intervalo de sensibilidade à força desejado e limitar² a corrente que flui no sensor. A Figura 3.6b ilustra a relação entre nível de força aplicada e tensão de saída para diversos valores de R_M , com uma tensão de alimentação (V_+) de +5 V.

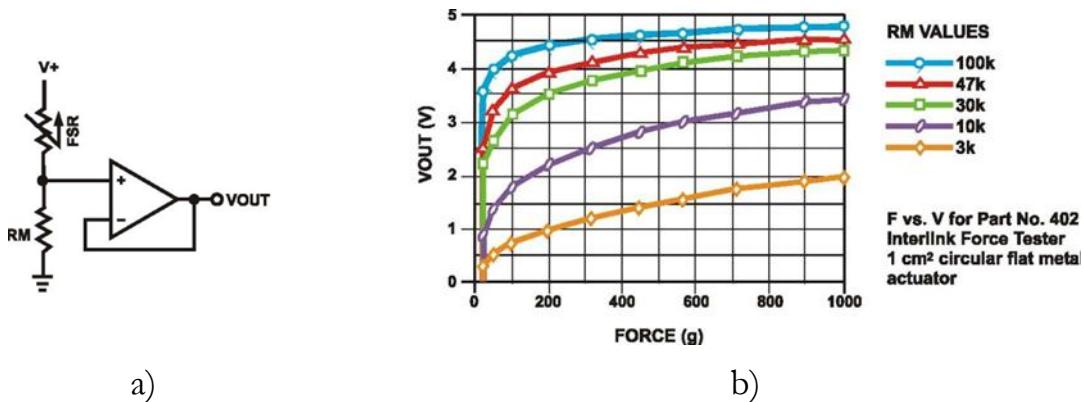


Figura 3.6 – FSR 402: a) Divisor de tensão com *buffer*; b) Curvas de tensão de saída vs. força para diferentes valores de R_M , em configuração de divisor de tensão e com V_+ de +5 V.

Fonte: Interlink Electronics (2010).

3.2.4 MATLAB e app Classification Learner

O MATLAB (abreviatura de “MATrix LABoratory”) é uma linguagem de programação de alto nível e ambiente de computação numérica desenvolvido pela MathWorks. É conhecido pela capacidade de manipulação de matrizes, implementação de algoritmos, criação de interfaces de utilizador e interoperabilidade com programas escritos noutras linguagens (Wikipedia contributors, 2023c).

Neste projeto, o MATLAB foi uma ferramenta crucial na fase de processamento dos dados e extração de características dos sinais EMG e FMG. As rotinas MATLAB implementadas lidaram com a leitura e o tratamento dos sinais, identificaram os pontos de início e fim das ativações musculares (*onset/offset*) e extraíram características consideradas relevantes. Além disso, o MATLAB foi importante na

¹ O amplificador operacional como buffer ajuda a isolar o divisor de tensão do resto do circuito, garantindo que a tensão de saída é uma representação precisa da força aplicada ao sensor FSR.

² Limitar a corrente é essencial para evitar sobrecarga térmica no sensor, prevenindo alterações na resistência devido ao efeito da temperatura.

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

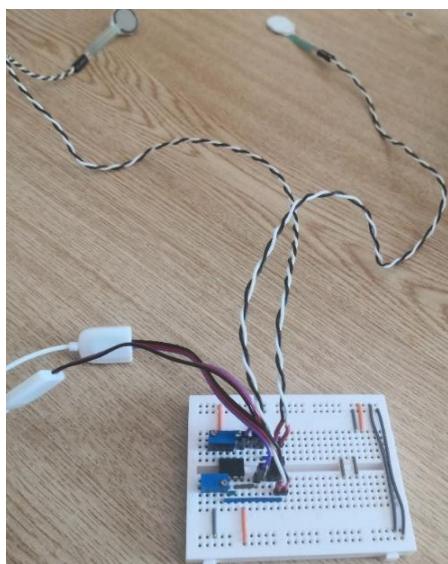
organização, *labeling* e separação das características extraídas em conjuntos de treino e teste, preparando assim o terreno para a fase de Supervised Learning.

No contexto do Supervised Learning, utilizou-se o Classification Learner, uma aplicação gráfica disponível na toolbox Statistics and Machine Learning do MATLAB. Através desta ferramenta, foi possível treinar, testar e comparar o desempenho de vários modelos de classificação, entre os quais SVMs, k-Nearest Neighbors (KNNs), e arquiteturas de redes neurais. Adicionalmente, facilitou o ajuste de hiperparâmetros e a seleção das características, aproveitando os vários métodos de ranking disponíveis: mRMR (minimum Redundancy Maximum Relevance), ANOVA, Kruskal-Wallis, ReliefF e Chi2. Além disso, a ferramenta também nos permitiu explorar recursos como matrizes de confusão e curvas ROC, ajudando-nos a compreender como os modelos lidam com cada uma das classes. Estas duas ferramentas foram cruciais para o *pipeline* de classificação de gestos.

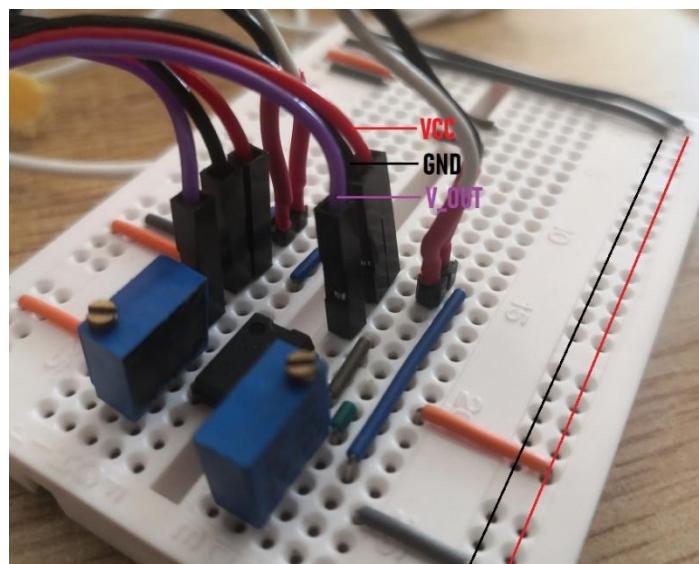
3.3 Aquisição dos sinais

3.3.1 Condicionamento dos sinais FMG

Para a obtenção dos sinais FMG, foi construído um circuito de condicionamento numa breadboard (Figura 3.7). Este circuito, com dois divisores de tensão acoplados ao mesmo amplificador operacional LM358, tem como função converter a força aplicada aos sensores em tensão para processamento pelo BITalino. A calibração dos sensores FSR, parte essencial neste processo, fez-se ajustando a resistência dos dois potenciômetros modelo 3296Y (de $100\text{ k}\Omega$). Este ajuste impede a saturação dos sensores, assegura a sensibilidade adequada e consequentemente garante a confiabilidade dos dados adquiridos.



a)



b)

Figura 3.7 – Circuito dos sinais FMG: a) Visão afastada, com sensores; b) Visão das ligações.

3.3.2 Procedimento de Aquisição dos Sinais

A implementação da aquisição dos sinais passou pelos seguintes passos:

- i. Para cada sessão de aquisição, os sensores EMG (em configuração bipolar) foram posicionados nos grupos musculares flexor e extensor, com uma separação aproximada de 2 cm.
- ii. Entre os dois elétrodos ativos, fixou-se um sensor FSR (numa base rígida de PVC¹) com um adesivo.
- iii. Aplicou-se uma fita de velcro no antebraço, sobre os dois sensores FMG em simultâneo, para estabilização dos sensores no lugar.
- iv. Cada participante foi instruído a executar uma série de ativações de um tipo específico de gesto, com durações e intervalos de descanso entre as ativações oscilando entre 1 e 3 segundos, para assegurar a representatividade dos dados recolhidos. Durante a recolha de dados, pediu-se ao participante para permanecer o mais relaxado possível entre as ativações e manter a articulação do cotovelo imóvel, para minimizar a influência de tensões musculares residuais nos dados recolhidos.
- v. Cada série de ativações foi registada num ficheiro distinto com a designação do gesto executado, utilizando o software OpenSignals. A taxa de amostragem foi de 1000 Hz.

A Figura 3.8 mostra imagens da aquisição de sinais:

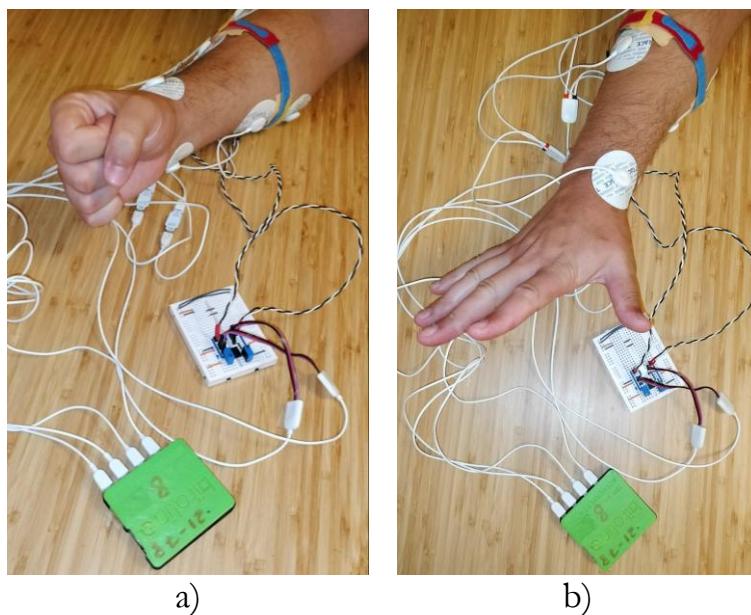


Figura 3.8 – Aquisição de sinais: a) No fecho da mão; b) Na abertura da mão.

¹ Os sensores FSR funcionam melhor quando montados numa base rígida, pois, quando a força é aplicada ao dispositivo, existe uma superfície contra a qual exercer essa força. Além disso, a base fornece uma camada adicional de proteção contra choques mecânicos e deformação.

No total, registaram-se 70 ficheiros de dados aptos para as etapas seguintes do estudo, distribuídos da seguinte maneira: abertura da mão (14), fecho da mão (16), *pinch* (11), *thumbs-up* (16) e apontar (15). Estes ficheiros foram selecionados após descartar outros devido a problemas na aquisição, como excesso de ruído, e posicionamento incorreto e/ou fixação inadequada dos sensores.

3.4 Processamento dos sinais e extração de características

Recorrendo ao software MATLAB, processaram-se os sinais e extraíram-se as respetivas características, por meio de um conjunto de rotinas previamente desenvolvidas, aproveitando o trabalho de anos anteriores. Esse conjunto compreende uma rotina principal, com o pipeline, juntamente com funções auxiliares para a deteção de onset/offset e a extração de características dos sinais de EMG e FMG. Os códigos são apresentados em anexo.

A rotina principal, implementada no MATLAB, executa uma série de etapas críticas no processamento de sinais:

- i. Filtragem de sinais EMG: para cada arquivo de texto (com dados EMG e FMG), o código aplica um filtro passa-banda de 20 a 500 Hz aos sinais EMG.
- ii. *Wavelet Denoising*: os sinais EMG passam por um segundo estágio de redução de ruído, desta vez usando a função `wdenoise` da Wavelet Toolbox do MATLAB. Esta técnica, que atua no domínio do tempo-frequência, elimina ruídos aleatórios que poderiam ser confundidos com a verdadeira atividade muscular (Wikipedia contributors, 2023g).
- iii. Deteção de onset e offset da atividade muscular: este é um passo crucial. O código utiliza a função `onsetting` para determinar quando o músculo realmente começou a contrair (onset) e quando parou (offset). O resultado são séries temporais (vetores) de onsets e offsets de contração muscular.

A função de onset/offset é responsável por identificar os momentos em que o sinal EMG demonstra uma atividade significativa. A função faz isso através da retificação de onda completa do sinal, aplicando uma média móvel para calcular a função de teste e definindo um limiar para a deteção de onset. Se o sinal cai abaixo desse limiar, um offset é detetado. Além disso, a função também garante que os momentos de atividade detetados tenham uma duração mínima para evitar falsas deteções (650 ms).

- iv. Ativações correspondentes: o código procura por ativações musculares que coincidem entre os sinais EMG das duas janelas musculares (extensora e flexora). Os tempos de onset e offset dos sinais FMG é dado pelos valores guardados para os sinais EMG correspondentes. A tolerância para a coincidência é dada pelo valor da constante `tolerance_window`, e foi mantida em 500 ms.

- v. Extração de características: Para cada ativação muscular que coincide, o código extrai um conjunto de características tanto dos sinais EMG como FMG. As características são medidas que proporcionam uma compreensão mais aprofundada dos sinais, que de outra forma seriam muito difíceis de interpretar.

As funções `extract_emg_features` e `extract_fmg_features` foram utilizadas para extrair características dos sinais EMG e FMG, respetivamente. Estas funções calculam uma conjunto de características, tanto no domínio do tempo quanto da frequência (no caso do EMG), para cada instância de um gesto, como apresentado na Tabela 3.3. No total foram extraídas 36 características, 12 EMG e 6 FMG para cada grupo muscular.

Tabela 3.3 – Características extraídas dos sinais EMG e FMG.

Característica	Descrição	Domínio	EMG	FMG
MAV (Mean Absolute Value)	Valor Médio Absoluto: a média dos valores absolutos do sinal.	Tempo	✓	
RMS (Root Mean Square)	Valor Quadrático Médio: a raiz quadrada da média dos quadrados dos valores do sinal; uma medida da magnitude do sinal.	Tempo	✓	✓
STD (Standard deviation)	Desvio-Padrão: medida de dispersão em torno da média do sinal.	Tempo	✓	✓
IQR (Interquartile range)	Amplitude interquartil: diferença entre o terceiro quartil e o primeiro quartil, dando uma ideia da dispersão dos dados.	Tempo	✓	
WL (Waveform Length)	Comprimento da forma de onda: soma das diferenças absolutas entre valores de sinal adjacentes.	Tempo	✓	✓
SSC (Slope Sign Changes)	Alterações de sinal de inclinação: número de mudanças na inclinação do sinal.	Tempo	✓	✓
IEMG (Integrated EMG)	EMG Integrado: soma dos valores absolutos do sinal, indicando a força muscular.	Tempo	✓	
KURT (Kurtosis)	Curtose: uma medida do achatamento do sinal, com relação à distribuição normal.	Tempo	✓	
LOG (Log Detector)	Detetor de log: medida da irregularidade do sinal.	Tempo	✓	
MNF (Mean Frequency)	Frequência Média: média ponderada das frequências do sinal.	Frequência	✓	
PKF (Peak Frequency)	Frequência de Pico: a frequência onde a densidade espectral de potência do sinal atinge o máximo.	Frequência	✓	
MNPSD (Mean Power Spectral Density)	Densidade Espectral Média de Potência: a média das potências em todas as frequências do sinal.	Frequência	✓	
Média	A média dos valores do sinal.	Tempo		✓
Mediana	O valor do meio do sinal quando ordenado.	Tempo		✓

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

A Figura 3.9 mostra os plots dos sinais EMG e FMG extraídos de uma amostra do gesto “abertura da mão”, com os onsets a verde e os offsets a vermelho.

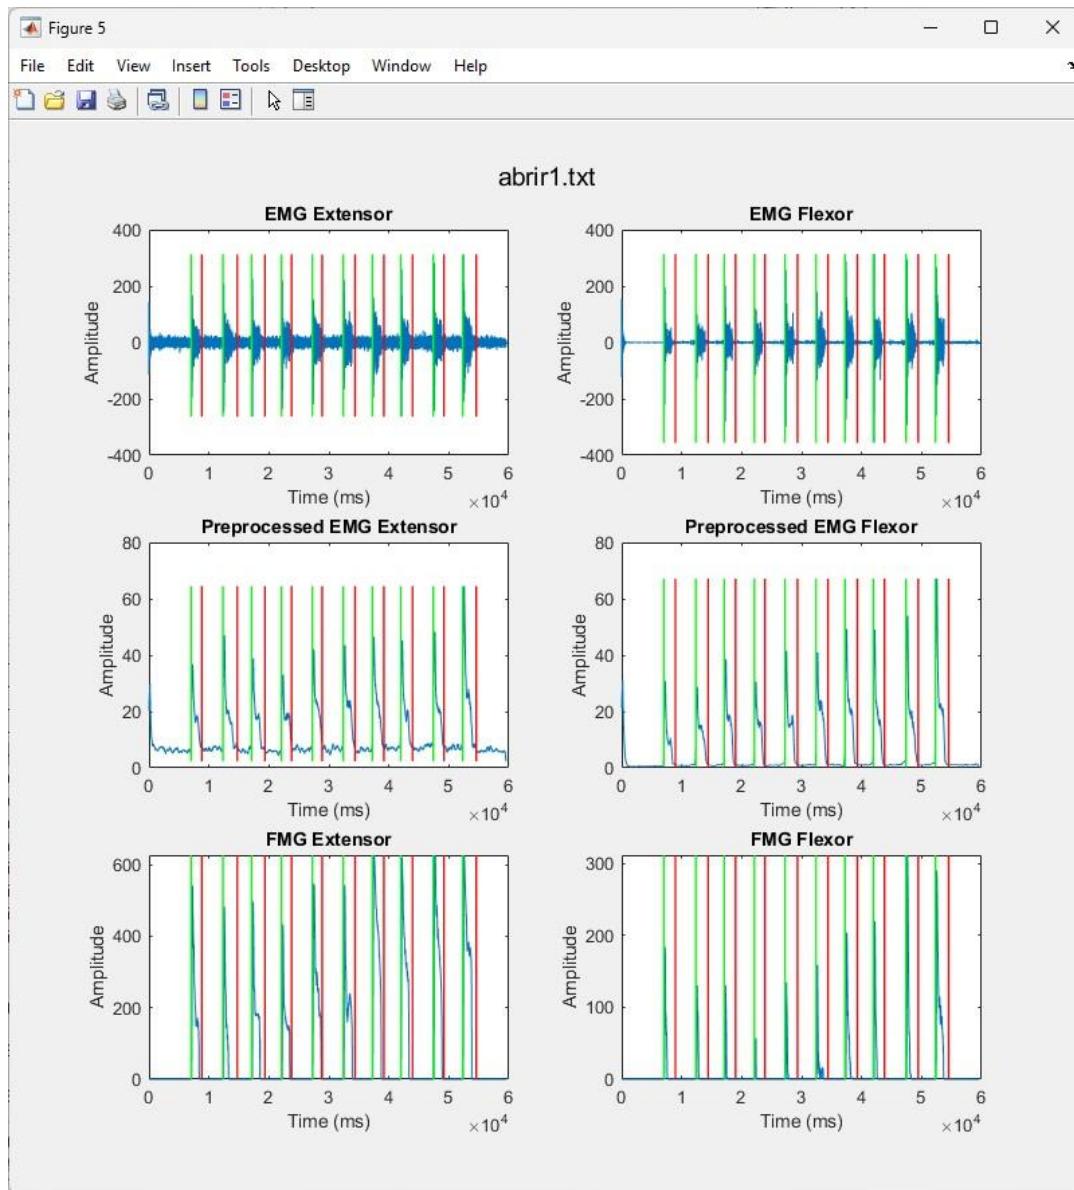


Figura 3.9 – Plots de sinais EMG e FMG obtidos na execução do gesto “abertura da mão”.

Nota: a figura é dividida em seis subplots. Os dois primeiros mostram os sinais EMG brutos dos músculos extensor e flexor, com os onsets e offsets de cada contração marcados em verde e vermelho, respetivamente. Os dois subplots seguintes correspondem aos sinais EMG pós-processados para os mesmos músculos. Nos dois últimos pode-se ver os sinais FMG.

3.5 Seleção e aplicação de classificadores

Esta seção descreve a abordagem sistemática que se seguiu para a seleção e aplicação de classificadores neste projeto. Utilizando a app Classification Learner do MATLAB, seguiu-se uma estratégia do geral para o particular, permitindo uma avaliação abrangente dos modelos. Assim:

- i. Comparação inicial de classificadores: numa primeira fase, fez-se uma comparação preliminar dos 33 modelos de classificação disponíveis, utilizando a *accuracy* (ou “eficácia”) como métrica principal.
- ii. Impacto da seleção de características nos modelos selecionados: após a seleção dos classificadores com melhor desempenho, conduziu-se um estudo aprofundado para compreender o impacto da seleção de características no desempenho desses modelos. Nesta fase, não só se continuou a considerar a *accuracy* como métrica de avaliação, mas também se introduziram métricas adicionais - o F-score e a área sob a curva ROC (ROC-AUC) - para obter uma visão mais completa do desempenho dos modelos.
- iii. Ajuste de hiperparâmetros: com base nas melhores combinações de método de classificação e percentil obtidas na fase anterior, procedeu-se à otimização dos hiperparâmetros para esses modelos. Esta etapa permitiu-nos aperfeiçoar ainda mais os modelos selecionados.
- iv. Comparação de desempenho entre utilização de todos os dados, somente EMG e somente FMG: em paralelo, fez-se uma comparação dos desempenhos dos modelos usando todas as características e características exclusivamente derivadas de EMG ou FMG. Este passo justifica-se pela prática tradicional de utilizar exclusivamente sinais EMG no controlo de próteses mioelétricas e por estudos que avaliam o desempenho de sistemas apenas com FMG. O objetivo desta comparação foi avaliar a viabilidade de cada um destes tipos de sinais para o controlo de próteses.

3.6 Métricas de desempenho

3.6.1 Accuracy

A *accuracy* (global) representa a percentagem de previsões corretas feitas pelo modelo. É calculada usando a seguinte fórmula:

$$\text{Accuracy} = \frac{(VP + VN)}{(VP + FP + VN + FN)} \quad (3.2)$$

Na equação (3.2), os termos VP, VN, FP e FN correspondem à classificação correta ou incorreta das instâncias pelo modelo: VP (Verdadeiros Positivo) indica o número de instâncias positivas classificadas corretamente como tal, VN (Verdadeiros Negativos) é número de instâncias negativas classificadas corretamente como negativas, FP (Falsos Positivos) representa número de instâncias negativas incorretamente classificadas como positivas, e FN (Falsos Negativos) o número de instâncias positivas que foram incorretamente classificadas como negativas.

A Figura 3.10 apresenta um exemplo de matriz de confusão para ilustrar a utilização desses termos em contexto de classificação binária (com apenas duas classes).

		Previsão	
		1	0
Real	1	VP	FN
	0	FP	VN

Figura 3.10 – Exemplo de matriz de confusão para classificadores binários.

3.6.2 Precisão e Sensibilidade (componentes do F-score)

A precisão e a sensibilidade são métricas que se aplicam individualmente a cada classe. A precisão representa a proporção de instâncias identificadas como positivas que são realmente positivas, e é calculada através da fórmula (3.3):

$$\text{Precisão} = \frac{\text{VP}}{(\text{VP} + \text{FP})} \quad (3.3)$$

Por sua vez, a sensibilidade (também conhecida como recall) representa a capacidade do modelo de identificar corretamente as instâncias positivas, é calculada através da fórmula (3.4):

$$\text{Sensibilidade} = \frac{\text{VP}}{(\text{VP} + \text{FN})} \quad (3.4)$$

Embora sensibilidade e a precisão não tenham sido utilizadas isoladamente neste estudo, foram utilizadas para o cálculo de outra métrica, o F-score.

3.6.3 F-score

O F-score, ou F1-score, é a média harmónica entre a precisão e a sensibilidade e é calculado através da seguinte fórmula:

$$\text{F-score} = \frac{2(\text{Precisão} \times \text{Sensibilidade})}{(\text{Precisão} + \text{Sensibilidade})} \quad (3.5)$$

O F-score é uma métrica aplicada em situações de classes desequilibradas, onde a precisão e a sensibilidade por si só podem não fornecer uma representação precisa do desempenho do modelo. Um F-score elevado indica que o modelo tem uma precisão e uma sensibilidade equilibradas, o que é especialmente importante em

situações em que tanto os falsos positivos (FP) quanto os falsos negativos (FN) são preocupantes.

Para este estudo, tratando-se de um problema de classificação multiclasse, calculou-se o F-score macro, ou seja, a média dos F-scores de todas as classes.

3.6.4 Área sob a Curva ROC (ROC-AUC)

A ROC-AUC é uma métrica que fornece uma visão geral da capacidade do modelo em distinguir entre as diferentes classes. É calculada através do plot de uma curva ROC, que é um gráfico que apresenta a sensibilidade (taxa de verdadeiros positivos) em função da taxa de verdadeiros negativos (1 – especificidade) para diferentes pontos de corte. A área sob esta curva (AUC) é então calculada (Wikipedia contributors, 2023f). Uma AUC de 1,0 indica um modelo perfeito, enquanto uma AUC de 0,5 indica um modelo que produz previsões completamente aleatórias.

No contexto de um problema multiclasse, a ROC-AUC é calculada como a média aritmética dos valores ROC-AUC para cada classe individualmente, que se denomina de ROC-AUC macro. Neste estudo, para calcular a ROC-AUC macro, utilizaram-se as curvas ROC produzidas pela aplicação Classification Learner para calcular a média aritmética dos valores ROC-AUC de cada classe. A Figura 3.11 apresenta um exemplo de curvas ROC geradas pelo Classification Learner.

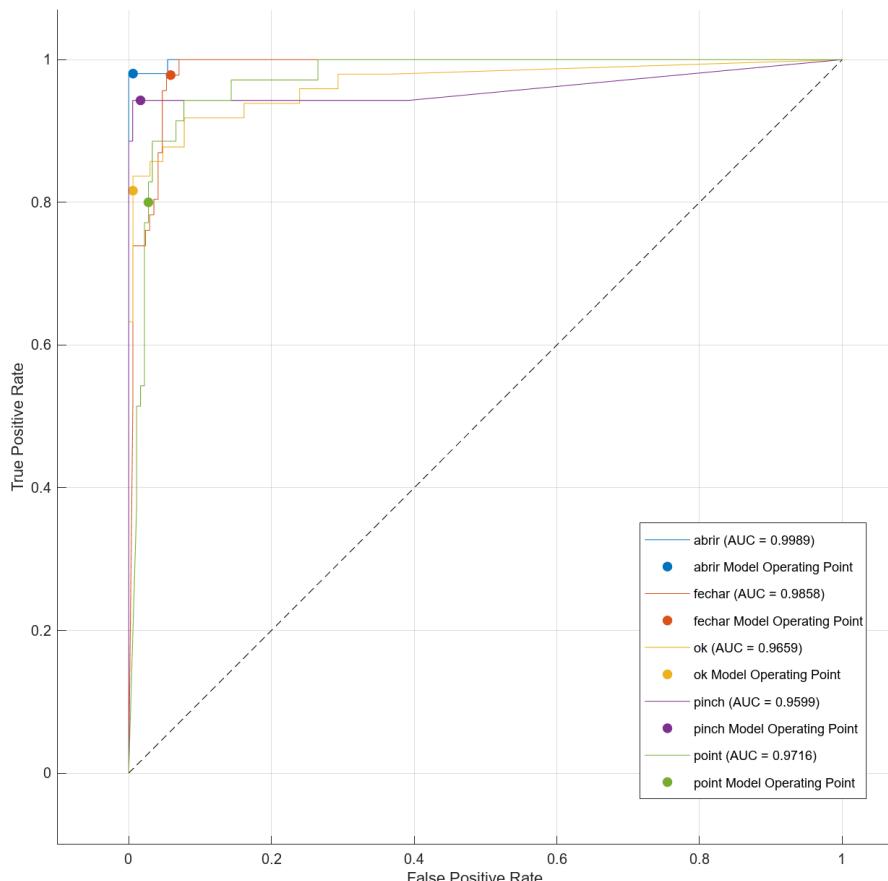


Figura 3.11 – Curvas ROC (teste) para as várias classes do modelo Weighted KNN optimizado.

4 RESULTADOS

4.1 Comparação de classificadores

Neste estudo, foram treinados e avaliados vários modelos de classificação, utilizando-se os algoritmos *built-in* da ferramenta Classification Learner do MATLAB. As técnicas aplicadas variaram desde abordagens mais lineares, como o Quadratic Discriminant, até métodos mais sofisticados, incluindo SVMs e arquiteturas de Redes Neurais.

Para uma primeira análise do desempenho dos modelos, leva-se em consideração as métricas de *accuracy* na validação e no teste. Estas métricas ajudam a entender a capacidade do modelo de prever corretamente as classes nos conjuntos de validação e de teste. A tabela a seguir apresenta essas métricas para todos os modelos analisados:

Tabela 4.1 – Avaliação inicial de desempenho dos classificadores.

Modelo	Accuracy % (Validação)	Accuracy % (Teste)	Tempo de treino (segundos)	Tamanho (bytes)
Fine Tree	71,64	74,07	7.6197	40125
Medium Tree	64,93	56,94	6.2133	16405
Coarse Tree	48,26	43,06	5.3740	10545
Linear Discriminant	74,07	75,46	4.7519	35106
Quadratic Discriminant	83,68	83,80	4.6320	130092
Efficient Logistic Regression	38,77	31,02	4.7715	173268
Efficient Linear SVM	62,85	68,06	5.0427	172824
Gaussian Naive Bayes	54,75	56,94	4.9100	34894
Kernel Naive Bayes	64,00	64,81	11.4956	1403362
Linear SVM	72,69	74,54	7.8024	104824
Quadratic SVM	89,35	87,96	4.6564	322120
Cubic SVM	89,24	87,96	5.5436	308744
Fine Gaussian SVM	74,88	72,69	7.7074	1116736
Medium Gaussian SVM	85,65	87,96	4.7845	526064
Coarse Gaussian SVM	64,00	62,96	4.6932	756800
Fine KNN	86,69	86,57	4.7361	273638
Medium KNN	83,80	85,65	4.6439	273638
Coarse KNN	60,30	65,28	4.6308	273638
Cosine KNN	80,56	84,26	4.6350	273626
Cubic KNN	81,02	83,80	3.9326	273654
Weighted KNN	86,92	88,43	3.8750	273656
Boosted Trees	73,73	68,52	6.5170	496322
Bagged Trees	85,88	83,33	6.5224	1296334
Subspace Discriminant	70,95	69,91	7.0128	443668
Subspace KNN	67,48	67,59	7.0090	4398154
RUSBoosted Trees	70,37	72,69	6.3818	496322

Modelo	Accuracy % (Validação)	Accuracy % (Teste)	Tempo de treino (segundos)	Tamanho (bytes)
Narrow Neural Network	79,51	78,70	7.6164	14757
Medium Neural Network	85,07	81,02	4.4633	19797
Wide Neural Network	88,43	82,41	5.5061	44997
Bilayered Neural Network	80,56	80,56	6.7127	16557
Trilayered Neural Network	80,09	75,46	7.1173	18357
SVM Kernel	63,89	67,13	15.3997	303174
Logistic Regression Kernel	57,99	60,65	9.3618	303570

Os resultados demonstram que diversos modelos de classificação exibiram um bom desempenho em termos de *accuracy* de validação e teste. Os melhores classificadores foram Quadratic SVM (89,35% e 87,96%), Cubic SVM (89,24% e 87,96%), Weighted KNN (86,92% e 88,43%), e Fine KNN (86,69% e 86,57%).

Adicionalmente, os modelos Quadratic Discriminant, Medium Gaussian SVM, Medium KNN, Cosine KNN, Cubic KNN, Bagged Trees e Medium Neural Network também se destacaram com performances interessantes. Em particular, é de notar que o modelo Wide Neural Network apresentou uma *accuracy* de 88,43% na validação, embora o seu desempenho tenha decrescido um pouco no teste (82,41%), o que pode ser um indicador de *overfitting*¹.

Com base nesses resultados, selecionaram-se os modelos que apresentaram as melhores desempenhos em termos de *accuracy* para uma análise mais aprofundada. Esta etapa envolveu o cálculo de métricas adicionais - o F-score e a área sob a curva ROC (ROC-AUC) - para esses modelos selecionados. Essas métricas fornecem uma visão mais completa do desempenho dos modelos. O F-score combina precisão e sensibilidade (ou *recall*) numa única métrica que avalia a precisão e robustez do modelo. A ROC-AUC, por outro lado, mede a capacidade do modelo de distinguir entre as classes.

Os resultados desta análise mais aprofundada estão resumidos na tabela a seguir:

Tabela 4.2 – F-score e ROC-AUC dos classificadores selecionados.

Modelo	F-score (Validação)	F-score (Teste)	ROC-AUC (Validação)	ROC-AUC (Teste)
Quadratic Discriminant	0,8377	0,8324	0,9370	0,9405
Quadratic SVM	0,8827	0,8758	0,9823	0,9733
Cubic SVM	0,8928	0,8788	0,9811	0,9669
Medium Gaussian SVM	0,8577	0,8772	0,9750	0,9676
Fine KNN	0,8687	0,8625	0,9180	0,9155
Medium KNN	0,8382	0,8514	0,9703	0,9620
Cosine KNN	0,8058	0,8371	0,9633	0,9704
Cubic KNN	0,8119	0,8338	0,9641	0,9533

¹ Overfitting em Machine Learning ocorre quando um modelo se ajusta excessivamente aos dados de treino, capturando ruído e flutuações aleatórias, levando a um desempenho inferior quando exposto a novos dados.

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

Modelo	F-score (Validação)	F-score (Teste)	ROC-AUC (Validação)	ROC-AUC (Teste)
Weighted KNN	0,8684	0,8810	0,9785	0,9709
Bagged Trees	0,8586	0,8276	0,9700	0,9643
Medium Neural Network	0,8514	0,8039	0,9527	0,9182
Wide Neural Network	0,8831	0,8179	0,9684	0,9410

Ao analisar as métricas F-score e ROC-AUC para validação e teste, algumas tendências interessantes emergem. O Cubic SVM sobressai com o F-score mais alto na validação (0,8928), seguido de perto pelo Quadratic SVM (0,8827) e pelo Wide Neural Network (0,8831). No *dataset* de teste, os modelos com os F-score mais destacados foram Weighted KNN (0,8810), Cubic SVM (0,8788), Medium Gaussian SVM (0,8772) e Quadratic SVM (0,8758).

Quanto à área sob a curva ROC (ROC-AUC), que mede a capacidade do modelo de distinguir entre as classes, novamente o Quadratic SVM e o Cubic SVM demonstraram performances excepcionais, com valores de 0,9823 e 0,9811 na validação e de 0,9733 e 0,9669 no teste, respectivamente. Também importa mencionar o desempenho do Weighted KNN, com valores de ROC-AUC de 0,9785 na validação e 0,9709 no teste.

A combinação destas duas etapas de seleção permitiu uma avaliação abrangente dos modelos. A seleção inicial, baseada na *accuracy*, proporcionou uma primeira filtragem dos modelos, e as métricas adicionais permitiram uma comparação mais refinada do desempenho entre os modelos selecionados.

4.2 Impacto da Seleção de Características

Aqui exploraram-se os efeitos de vários métodos de seleção de características e percentis no desempenho dos nossos modelos de Machine Learning. Empregaram-se diversas técnicas de ranking de características - mRMR, Chi2, ReliefF, ANOVA e Kruskal-Wallis - para avaliar a importância de cada característica e determinar quais eram mais relevantes para os nossos modelos. Além disso, experimentaram-se diferentes percentis de características para os modelos – 30, 24, ou 18 das 36 iniciais - com o objetivo de identificar o equilíbrio ideal entre complexidade do modelo e poder de predição dos gestos.

A Tabela 4.3 e a Tabela 4.4 dão continuidade à análise dos modelos que mostraram os melhores desempenhos na seção 4.1. Desta vez, o nosso foco é o impacto da seleção de características na eficácia destes modelos, tanto para validação quanto para teste. Para uma visão completa dos resultados de todos os modelos, podem-se consultar as tabelas fornecidas no Anexo F.

Analizando globalmente os resultados obtidos, destacam-se os desempenhos dos modelos Cubic SVM e Quadratic SVM, que apresentaram uma robustez notável, mantendo um nível de eficácia elevado, quer na validação, quer no conjunto de teste, independentemente do número de características ou do método de seleção usado.

Especificamente, o modelo Cubic SVM alcançou 88,08% na validação com 18 características selecionadas pelo método ReliefF, e 90,28% no conjunto de teste, com a seleção de 18 características utilizando o método Chi2. Os modelos Fine KNN e Weighted KNN mostraram-se também bastante resilientes, mantendo uma eficácia assinalável tanto na validação como nos testes, ainda que inferior à dos modelos SVM.

Os resultados indicam uma robustez variável dos modelos em face da seleção de características. Enquanto a maioria dos modelos mostrou resiliência, mantendo a eficácia mesmo com a redução do número de características, alguns modelos, em particular o Quadratic Discriminant, demonstraram maior sensibilidade a essa redução. A eficácia deste modelo caiu drasticamente ao limitar a 18 o número de características selecionadas pelos métodos ANOVA e Kruskal-Wallis. Em contraste, os modelos Cubic SVM, Fine KNN e Weighted KNN destacaram-se pela sua robustez, mantendo ou até melhorando a sua eficácia mesmo com a redução do número de características.

*Reconhecimento de gestos através da implementação de sistema bimodal de aquisição
de sinais EMG e FMG*

Tabela 4.3 – Desempenho de validação dos modelos para diferentes métodos de ranking de características e número de características.

VALIDAÇÃO	Nenhum	mRMR (30)	mRMR (24)	mRMR (18)	Chi2 (30)	Chi2 (24)	Chi2 (18)	ReliefF (30)	ReliefF (24)	ReliefF (18)	ANOVA (30)	ANOVA (24)	ANOVA (18)	Kruskal (30)	Kruskal (24)	Kruskal (18)
Quadratic Discriminant	83,33	83,33	81,13	80,21	82,87	82,06	80,44	83,10	82,75	82,64	82,87	81,48	71,18	81,94	79,98	67,94
Quadratic SVM	90,05	87,73	86,69	85,88	87,50	87,73	85,65	89,00	87,38	86,69	88,19	86,92	78,59	87,73	86,11	80,67
Cubic SVM	89,35	88,66	88,31	87,62	89,35	86,34	86,23	89,00	87,96	88,08	89,58	88,66	83,45	88,43	86,92	79,86
Medium Gaussian SVM	86,92	85,53	84,49	84,61	84,14	83,80	84,61	85,53	86,23	85,88	86,23	85,19	79,75	84,38	83,45	78,36
Fine KNN	88,19	87,04	86,81	86,81	88,77	87,50	86,23	90,16	87,15	87,85	89,70	89,58	84,72	88,89	86,57	82,99
Medium KNN	82,75	82,06	83,33	82,64	82,64	82,18	81,83	83,68	82,99	83,91	82,64	83,68	81,71	81,48	82,06	77,55
Cosine KNN	81,02	81,25	81,60	80,44	79,63	79,28	78,24	82,99	80,90	81,71	81,02	81,25	77,55	80,32	79,51	74,19
Cubic KNN	81,02	79,98	80,79	80,90	80,21	81,60	80,67	82,41	82,52	82,75	81,83	81,94	80,79	80,44	78,82	77,66
Weighted KNN	87,27	86,11	86,57	85,30	86,57	86,81	85,53	87,15	86,81	87,73	86,81	87,04	83,80	86,69	85,19	82,99
Bagged Trees	83,91	85,65	85,65	83,68	83,45	82,52	83,45	84,38	82,99	83,80	83,33	85,19	82,06	84,49	83,80	79,05
Medium Neural Network	84,61	85,53	81,71	85,65	84,26	83,91	82,64	84,14	83,22	85,53	83,80	82,99	75,93	83,10	83,91	78,94
Wide Neural Network	87,15	86,00	86,23	83,68	85,42	85,30	85,65	84,26	85,88	86,00	86,46	85,07	81,60	85,76	85,30	78,70

Tabela 4.4 – Desempenho de teste dos modelos para diferentes métodos de ranking de características e número de características.

TESTE	Nenhum	mRMR (30)	mRMR (24)	mRMR (18)	Chi2 (30)	Chi2 (24)	Chi2 (18)	ReliefF (30)	ReliefF (24)	ReliefF (18)	ANOVA (30)	ANOVA (24)	ANOVA (18)	Kruskal (30)	Kruskal (24)	Kruskal (18)
Quadratic Discriminant	83.80	80.56	77.31	81.94	82.87	78.70	81.48	81.02	81.02	81.94	81.02	82.87	66.20	81.48	77.31	65.28
Quadratic SVM	88.43	84.72	85.19	84.72	86.57	85.65	85.65	86.57	87.96	85.65	87.96	86.11	79.17	87.04	85.19	79.17
Cubic SVM	87.96	87.04	86.57	86.11	89.35	88.43	90.28	90.28	90.28	88.89	88.89	88.43	81.48	87.50	87.50	83.80
Medium Gaussian SVM	87.96	87.04	85.65	86.57	87.04	84.72	85.19	87.96	87.96	86.11	86.11	85.65	76.39	87.04	86.11	78.24
Fine KNN	86.57	85.65	84.72	87.50	85.19	85.19	86.11	88.89	87.96	87.04	87.04	85.65	84.72	86.11	84.26	81.94
Medium KNN	85.65	83.33	81.48	85.19	86.57	82.41	81.94	85.19	83.80	81.02	83.80	85.65	78.70	85.19	83.33	79.63
Cosine KNN	84.26	84.26	77.78	81.02	83.33	81.94	82.41	87.96	84.72	82.41	84.72	84.26	75.00	83.80	81.48	75.00
Cubic KNN	83.80	82.41	81.02	81.94	84.26	79.63	82.87	83.80	81.94	80.09	82.41	83.33	77.31	83.80	80.09	77.78
Weighted KNN	88.43	87.96	85.65	88.43	87.50	86.57	87.50	87.96	86.57	86.11	86.11	89.35	83.80	88.43	87.50	85.65
Bagged Trees	83.33	84.72	87.04	84.72	84.26	84.72	83.33	84.26	84.26	82.41	84.72	83.33	76.85	84.72	81.94	82.41
Medium Neural Network	85.65	79.17	81.48	82.41	81.02	79.63	81.02	81.02	85.19	79.17	84.72	83.33	76.39	82.87	80.56	76.39
Wide Neural Network	82.41	83.33	82.87	83.80	82.41	85.19	81.94	83.80	84.72	86.11	85.65	83.80	74.07	86.57	85.65	80.56

4.3 Otimização dos melhores modelos

Nesta fase, passou-se para a etapa final do processo de modelação: o ajuste dos hiperparâmetros dos modelos que foram identificados como os mais promissores nas seções anteriores.

Os hiperparâmetros são configurações externas ao modelo, que podem ser ajustados para controlar a forma como o modelo vai “aprender” (Wikipedia contributors, 2023a). Ao contrário dos parâmetros do modelo, os hiperparâmetros não são aprendidos a partir dos dados durante o treino, mas decididos à partida. Exemplos de hiperparâmetros incluem o número de “neurónios” ou camadas numa Rede Neural, o tipo de *kernel* num modelo SVM (linear, polinomial, etc.) ou o número de vizinhos num modelo KNN.

Para fazer uma analogia com uma situação real, considere-se o treino para correr uma maratona. Os hiperparâmetros seriam semelhantes ao plano de treino que se estabelece antes de começar a treinar, como o número de treinos por semana ou a intensidade desses treinos. Os parâmetros, por outro lado, são as variáveis que se vão ajustando durante o treino. Por exemplo, o ritmo de corrida, o batimento cardíaco e a respiração. Estes vão se adaptando em tempo real de forma a obter o melhor desempenho possível.

A Tabela 4.5 ajuda a esclarecer as diferenças fundamentais entre os dois conceitos:

Tabela 4.5 – Diferenças entre parâmetros e hiperparâmetros.

Parâmetros	Hiperparâmetros
Utilizados para fazer previsões	Utilizados para otimizar o modelo
Aprendidos pelo modelo	Configurados externamente
Internos ao modelo	Externos ao modelo
Dependentes do conjunto de dados	Independentes do conjunto de dados
Valores modificados durante o treino	Valores definidos antes do algoritmo
Treino do modelo → ajuste dos parâmetros	Ajuste dos hiperparâmetros → seleção dos melhores hiperparâmetros

O ajuste dos hiperparâmetros é uma etapa crucial no processo, pois permite-nos otimizar o desempenho dos modelos, melhorando a sua capacidade de generalizar a partir dos dados de treino para dados novos.

Com base na avaliação dos modelos realizada na seção anterior, identificaram-se os seguintes modelos como os mais promissores: Quadratic SVM, Cubic SVM, Fine KNN e Weighted KNN. Estes modelos apresentaram os melhores desempenhos, tanto nos conjuntos de dados de treino quanto de validação, e por isso serão objeto de nossa atenção nesta seção.

Adicionalmente, decidiu-se incluir um modelo de Wide Neural Network no ajuste dos hiperparâmetros, apesar do seu desempenho global ter sido ligeiramente inferior

aos modelos selecionados anteriormente. A razão para a inclusão deste modelo é que as redes neurais têm a capacidade de capturar interações complexas e não lineares entre as características que outros modelos podem não ser capazes de identificar.

Prosseguindo, cada um dos modelos selecionados – Quadratic SVM, Cubic SVM, Fine KNN, Weighted KNN e Wide Neural Network – será otimizado com o objetivo de encontrar a melhor combinação de hiperparâmetros e estratégias de seleção de características para cada modelo.

Os modelos foram avaliados com 100% das características e subconjuntos obtidos pelos métodos de seleção, usando diferentes percentis. As combinações com melhor desempenho, apresentadas na seção 4.2, serão agora exploradas mais a fundo.

Na escolha destas combinações, privilegiou-se os resultados de teste, contudo os resultados de validação foram também considerados. Este procedimento foi fundamental para assegurar que os bons resultados observados nos dados de teste não eram consequência de uma particularidade deste subconjunto, que poderia ser "mais fácil" de prever ou mais favorável a certos modelos. De seguida, as combinações ótimas por modelo:

Quadratic SVM:

Sem seleção de características (88,43% no teste, 90,05% na validação)

ANOVA (30) (87,96% no teste, 88,19% na validação)

RelieffF (30) (86,57% no teste, 89,00% na validação)

Cubic SVM:

Sem seleção de características (87,96% no teste, 89,35% na validação)

RelieffF (30) (90,28% no teste, 89,00% na validação)

Chi2 (18) (90,28% no teste, 86,23% na validação)

Weighted KNN:

Sem seleção de características (85,65% no teste, 87,15% na validação)

RelieffF (30) (85,19% no teste, 87,26% na validação)

ANOVA (30) (84,72% no teste, 87,15% na validação)

Fine KNN:

Sem seleção de características (86,57% no teste, 88,19% na validação)

RelieffF (30) (88,89% no teste, 90,16% na validação)

ANOVA (30) (87,04% no teste, 89,70% na validação)

Wide Neural Network:

Sem seleção de características (82,41% no teste, 87,15% na validação)

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

ReliefF (18) (86,11% no teste, 86,00% na validação)

Chi2 (24) (85,19% no teste, 85,30% na validação)

Para ajustar os hiperparâmetros dos modelos, recorreu-se ao Classification Learner do MATLAB, adotando o método de otimização Bayesiana - uma técnica cujos detalhes vão além deste estudo. Treinaram-se modelos SVM, KNN e Neural Network otimizáveis. Seguem os detalhes (Tabela 4.6):

Tabela 4.6 – Detalhes do ajuste de hiperparâmetros.

Modelo	Hiperparâmetros Fixados	Método de Seleção	Nº de Características
Quadratic SVM	Kernel function: Quadrática	Sem seleção	Todas
Quadratic SVM	Kernel function: Quadrática	ANOVA	30
Quadratic SVM	Kernel function: Quadrática	ReliefF	30
Cubic SVM	Kernel function: Cúbica	Sem seleção	Todas
Cubic SVM	Kernel function: Cúbica	ReliefF	30
Cubic SVM	Kernel function: Cúbica	Chi2	18
Fine KNN	Neighbors: 1, Distance Weight: Igual	Sem seleção	Todas
Fine KNN	Neighbors: 1, Distance Weight: Igual	ReliefF	30
Fine KNN	Neighbors: 1, Distance Weight: Igual	ANOVA	30
Weighted KNN	Nenhum	Sem seleção	Todas
Weighted KNN	Nenhum	ReliefF	30
Weighted KNN	Nenhum	ANOVA	30
Wide Neural Network	Number of fully connected layers: 1, First Layer Size: 100	Sem seleção	Todas
Wide Neural Network	Number of fully connected layers: 1, First Layer Size: 100	ReliefF	18
Wide Neural Network	Number of fully connected layers: 1, First Layer Size: 100	Chi2	24

Aqui podem-se ver os hiperparâmetros que se mantiveram fixos para cada modelo, sendo que os restantes foram alvos de ajuste. A tabela também inclui o método de seleção de características utilizado, bem como o número de características¹.

Para avaliar a eficácia do ajuste de hiperparâmetros na melhoria da performance dos nossos modelos de classificação, compararam-se as métricas de *accuracy* do conjunto de teste e validação antes e depois do ajuste.

Os modelos estudados incluíram Support Vector Machines (SVMs) com funções de kernel quadráticas e cúbicas, k-Nearest Neighbors com pesos ajustados e finos, bem como Redes Neurais de arquitetura larga. Cada um desses modelos foi treinado utilizando o conjunto total de características, bem como subconjuntos selecionados de características usando os métodos ANOVA, ReliefF e Chi2.

A Tabela 4.7 fornece uma visão geral dos resultados:

¹ Os rankings gerados pelos métodos de seleção podem ser consultados em anexo.

Tabela 4.7 – Impacto do ajuste de hiperparâmetros na performance dos modelos.

Modelo	Seleção de Características	Validação Pré-ajuste	Teste Pré-ajuste	Validação Pós-ajuste	Teste Pós-ajuste
Quadratic SVM	Sem seleção	90,05%	88,43%	90,28%	88,89%
Quadratic SVM	ANOVA (30)	88,19%	87,96%	89,24%	87,50%
Quadratic SVM	ReliefF (30)	89,00%	86,57%	90,16%	87,50%
Cubic SVM	Sem seleção	89,35%	87,96%	90,51%	87,96%
Cubic SVM	ReliefF (30)	89,00%	90,28%	89,70%	88,89%
Cubic SVM	Chi2 (18)	86,23%	90,28%	86,00%	88,43%
Weighted KNN	Sem seleção	87,15%	85,65%	89,47%	90,74%
Weighted KNN	ReliefF (30)	87,26%	85,19%	90,05%	88,89%
Weighted KNN	ANOVA (30)	87,15%	84,72%	89,00%	87,04%
Fine KNN	Sem seleção	88,19%	86,57%	89,12%	90,74%
Fine KNN	ReliefF (30)	90,16%	88,89%	90,05%	88,89%
Fine KNN	ANOVA (30)	89,70%	87,04%	88,31%	87,04%
Wide Neural Network	Sem seleção	87,15%	82,41%	90,63%	85,19%
Wide Neural Network	ReliefF (18)	86,00%	86,11%	89,81%	88,89%
Wide Neural Network	Chi2 (24)	85,30%	85,19%	89,58%	86,57%

Analizando a tabela, identifica-se o impacto significativo da otimização de hiperparâmetros na melhoria da eficácia de quase todos os modelos. O Quadratic SVM teve melhor performance sem seleção de características, enquanto o Cubic SVM beneficiou de uma seleção de 30 características pelo método ReliefF. Ambos os modelos KNN exibiram ganhos notáveis de performance com o ajuste, principalmente sem seleção de características. Redes neurais de arquitetura larga melhoraram significativamente com o ajuste, com destaque para o uso do método ReliefF na seleção de características. Na tabela surgem destacadas as melhores combinações de hiperparâmetros e seleção de características para cada modelo.

Apesar das métricas de *accuracy* fornecerem um primeiro olhar sobre o desempenho dos modelos, é essencial considerar métricas adicionais para uma avaliação mais completa. Em particular, para problemas de classificação multiclasse como este, o F-score (macro) e a área sob a curva ROC (ROC-AUC) são muitas vezes usadas. Com base nisso, analise-se a Tabela 4.8 que resume as métricas de *accuracy*, F-score e ROC-AUC para estes modelos.

Tabela 4.8 – Desempenho dos Modelos: *accuracy*, F-Score e ROC-AUC.

Modelo	Accuracy (Validação)	Accuracy (Teste)	F-Score (Validação)	F-Score (Teste)	ROC-AUC (Validação)	ROC-AUC (Teste)
Quadratic SVM	90,28%	88,89%	0,9030	0,8858	0,9806	0,9710
Cubic SVM	89,00%	90,28%	0,8914	0,9046	0,9798	0,9751
Fine KNN	89,12%	90,74%	0,8926	0,9012	0,9331	0,9396
Weighted KNN	89,47%	90,74%	0,8956	0,9027	0,9816	0,9764
Wide NN	89,81%	88,89%	0,8974	0,8860	0,9839	0,9683

*Reconhecimento de gestos através da implementação de sistema bimodal de aquisição
de sinais EMG e FMG*

Observando os resultados da tabela, é possível verificar que todos os modelos têm desempenhos bastante próximos. Ainda assim, se se considerar os modelos com a melhor eficácia no conjunto de teste (Fine KNN e Weighted KNN), o Weighted KNN destaca-se por mostrar maior robustez nas restantes métricas. De facto, apresenta um dos melhores F-Scores (sinal de que equilibra de forma eficaz a precisão e a sensibilidade entre todas as classes) e o maior ROC-AUC, sugerindo um desempenho superior na classificação das diferentes classes.

Além disso, o modelo Weighted KNN, por ser menos complexo, é mais fácil de interpretar que Redes Neurais ou SVM, frequentemente consideradas "caixas-pretas" devido à opacidade na forma como fazem as suas previsões (Petch et al., 2022).

A abordagem do modelo KNN é essencialmente geométrica: para um novo ponto de entrada, o algoritmo procura pelos k pontos mais próximos no hiperespaço de características (onde cada dimensão corresponde a uma característica), e a previsão é uma função (como uma média ponderada) desses pontos vizinhos (Wikipedia contributors, 2023b). No caso específico do Weighted KNN, os vizinhos mais próximos têm maior peso no cálculo da previsão. Isto significa que os dados de treino mais semelhantes ao ponto de entrada têm maior influência na previsão final. Esta é uma abordagem intuitiva, quando comparada com o processo de aprendizagem pouco transparente das Redes Neurais e SVM.

As figuras seguintes (Figura 4.1 a Figura 4.10) apresentam as matrizes de confusão para todos os modelos treinados - Weighted KNN, Quadratic SVM, Cubic SVM, Fine KNN, e Wide Neural Network. A inclusão dessas matrizes ajuda a entender como cada modelo lida com as diferentes classes e fornece uma compreensão visual dos desempenhos dos modelos.

		abrir	fechar	ok	pinch	point
True Class	abrir	159			1	1
	fechar	1	152	11	7	8
ok		10	183		4	4
pinch		6	1	109		7
point	1	10	13	6		170
		abrir	fechar	ok	pinch	point
		Predicted Class				

Figura 4.1 – Matriz de confusão (validação): Weighted KNN.

		abrir	fechar	ok	pinch	point
True Class	abrir	50		1		
	fechar		45		1	
ok		6	40			3
pinch				33		2
point	1	4		2		28
		abrir	fechar	ok	pinch	point
		Predicted Class				

Figura 4.2 – Matriz de confusão (teste): Weighted KNN.

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

		abrir	fechar	ok	pinch	point
True Class	abrir	158		2		1
	fechar	1	159	5	6	8
ok		9	180		3	9
pinch		5	1	106		11
point		8	8	7		177
		abrir	fechar	ok	pinch	point
Predicted Class						

Figura 4.3 – Matriz de confusão (validação): Quadratic SVM.

		abrir	fechar	ok	pinch	point
True Class	abrir	49	1			1
	fechar	1	44	1		
ok		4	38		1	6
pinch		2	2	29		2
point		2	1			32
		abrir	fechar	ok	pinch	point
Predicted Class						

Figura 4.4 – Matriz de confusão (teste): Quadratic SVM.

		abrir	fechar	ok	pinch	point
True Class	abrir	156		3		2
	fechar	1	152	9	8	9
ok		12	177		2	10
pinch		4		108		11
point	2	7	8	7		176
Predicted Class		abrir	fechar	ok	pinch	point

Figura 4.5 – Matriz de confusão (validação): Cubic SVM.

		abrir	fechar	ok	pinch	point
True Class	abrir	49	1	1		
	fechar	1	44	1		
ok		10	38			1
pinch		1	1	30		3
point			1			34
Predicted Class		abrir	fechar	ok	pinch	point

Figura 4.6 – Matriz de confusão (teste): Cubic SVM.

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

		abrir	fechar	ok	pinch	point
True Class	abrir	157	1	2	1	
	fechar	2	151	12	4	10
ok		11	181	4	5	
pinch		4	1	110	8	
point		12	9	8	171	
		abrir	fechar	ok	pinch	point
Predicted Class						

Figura 4.7 – Matriz de confusão (validação): Fine KNN.

		abrir	fechar	ok	pinch	point
True Class	abrir	50		1		
	fechar		46			
ok		7	40			2
pinch				33		2
point	1	3		4		27
		abrir	fechar	ok	pinch	point
Predicted Class						

Figura 4.8 – Matriz de confusão (teste): Fine KNN.

		abrir	fechar	ok	pinch	point
True Class	abrir	158	1	2		
	fechar	2	159	6	3	9
ok	1	13	181	3	3	
pinch	1	6	1	103	12	
point	1	7	9	8	175	
		abrir	fechar	ok	pinch	point

Figura 4.9 – Matriz de confusão (validação): Wide Neural Network.

		abrir	fechar	ok	pinch	point
True Class	abrir	49		1		1
	fechar	1	45			
ok	1	9	38	1		
pinch			4	27	4	
point	1	1			33	
		abrir	fechar	ok	pinch	point

Figura 4.10 – Matriz de confusão (teste): Wide Neural Network.

4.4 Comparação dos resultados de características EMG e FMG

Nesta seção, explora-se o impacto de combinar características EMG e FMG no desempenho dos classificadores. Para isto, contrastou-se a abordagem bimodal com a prática mais comum que recorre exclusivamente a características EMG. A Tabela 4.9 a seguir detalha a performance dos classificadores quando utilizam todas as características, apenas características EMG e apenas características FMG. Os resultados são baseados na avaliação inicial dos classificadores, apresentada na seção 4.1, sem seleção de características ou ajuste de hiperparâmetros.

Tabela 4.9 – Comparação da *accuracy* dos classificadores entre utilização de todos os dados, somente EMG e somente FMG.

Classificador	Validação (Todos os dados)	Teste (Todos os dados)	Validação (EMG)	Teste (EMG)	Validação (FMG)	Teste (FMG)
Fine Tree	71,64	74,07	68,29	67,13	56,94	60,19
Medium Tree	64,93	56,94	62,5	59,26	50,93	52,31
Coarse Tree	48,26	43,06	47,57	43,06	41,67	42,59
Linear Discriminant	74,07	75,46	62,96	64,35	50,69	53,24
Quadratic Discriminant	83,68	83,8	73,15	72,69	55,32	57,41
Efficient Logistic Regression	38,77	31,02	34,72	26,85	47,92	50,93
Efficient Linear SVM	62,85	68,06	56,02	55,56	47,57	46,76
Gaussian Naive Bayes	54,75	56,94	48,96	51,85	49,19	50,46
Kernel Naive Bayes	64	64,81	58,45	57,41	49,65	49,07
Linear SVM	72,69	74,54	65,16	65,74	52,43	52,78
Quadratic SVM	89,35	87,96	79,28	75	65,16	68,06
Cubic SVM	89,24	87,96	79,4	79,63	70,49	70,37
Fine Gaussian SVM	74,88	72,69	75,93	75,46	66,32	68,06
Medium Gaussian SVM	85,65	87,96	73,15	75,46	56,83	58,33
Coarse Gaussian SVM	64	62,96	53,36	52,31	47,11	45,83
Fine KNN	86,69	86,57	74,88	80,09	65,05	63,43
Medium KNN	83,8	85,65	73,03	76,85	62,73	63,89
Coarse KNN	60,3	65,28	58,8	57,41	52,2	51,85
Cosine KNN	80,56	84,26	71,06	71,3	60,53	57,41
Cubic KNN	81,02	83,8	70,37	70,83	62,38	62,04
Weighted KNN	86,92	88,43	75,58	77,31	67,25	64,81
Boosted Trees	73,73	68,52	69,68	70,37	53,47	58,8
Bagged Trees	85,88	83,33	76,97	81,94	65,05	65,74
Subspace Discriminant	70,95	69,91	62,85	62,96	50,35	51,85
Subspace KNN	67,48	67,59	60,3	65,28	55,67	55,09
RUSBoosted Trees	70,37	72,69	68,06	67,59	54,63	53,7
Narrow NN	79,51	78,7	73,96	74,54	63,19	68,52
Medium NN	85,07	81,02	74,54	75	59,49	60,19
Wide NN	88,43	82,41	78,47	79,17	67,25	68,06
Bilayered NN	80,56	80,56	72,22	74,07	60,76	69,44

Classificador	Validação (Todos os dados)	Teste (Todos os dados)	Validação (EMG)	Teste (EMG)	Validação (FMG)	Teste (FMG)
Trilayered NN	80,09	75,46	67,94	78,24	60,19	59,72
SVM Kernel	63,89	67,13	59,03	61,57	55,79	53,24

Examinando os dados da tabela, algumas tendências e particularidades emergem. Em geral, a eficácia da maioria dos classificadores é maior quando se utiliza uma combinação de características EMG e FMG, em vez de apenas uma delas.

No entanto, existem exceções notáveis a esta tendência. Por exemplo, para o classificador Fine Gaussian SVM, a eficácia obtida com a utilização exclusiva de características EMG é ligeiramente superior à obtida com todos os dados. Isso indica que, para certos classificadores, a informação EMG pode ser suficiente para alcançar um bom desempenho, eliminando a necessidade de incluir características FMG. Curiosamente, para o classificador Efficient Logistic Regression, o desempenho quando utiliza apenas características FMG supera aquele quando utiliza todas as características ou apenas EMG. Este é um caso peculiar que destaca como certos classificadores podem ser mais adequados para conjuntos específicos de características.

5 DISCUSSÃO DOS RESULTADOS

Este estudo permite perceber aspectos importantes sobre a implementação de classificadores na tarefa de reconhecimento de gestos. Em particular, os modelos Quadratic SVM, Cubic SVM, Weighted KNN e Fine KNN destacam-se em termos de *accuracy*, F-score e a área sob a curva ROC. Estas medidas indicam uma forte capacidade de distinguir entre diferentes classes de gestos, sugerindo que esses modelos têm grande potencial para esta aplicação específica.

Além disso, nota-se que a seleção de características teve um papel crítico no desempenho dos modelos. Os modelos Quadratic SVM e Cubic SVM exibiram robustez face à variação do número de características selecionadas, indicando que estes modelos são menos sensíveis à quantidade de informações de entrada. Por outro lado, o modelo Quadratic Discriminant, para referir um exemplo, mostrou uma queda de desempenho significativa com a redução do número de características, sinalizando a importância da seleção cuidadosa de características para alguns tipos de modelo.

Também vale a pena destacar o impacto da otimização de hiperparâmetros no desempenho dos modelos. Especificamente, os modelos KNN e as Redes Neurais beneficiaram de sobremaneira deste ajuste.

Tratando-se de um problema de classificação multiclasse, a seleção das métricas para avaliação do desempenho dos modelos desempenha um papel crucial. Dado o desequilíbrio das classes observado - abrir (212 instâncias), fechar (225 instâncias), *pinch* (158 instâncias), *thumbs-up* (250 instâncias), apontar (235 instâncias) - a *accuracy* por si só não proporcionava uma visão ampla o suficiente do desempenho dos modelos. Foi nesta perspetiva que se optou pela inclusão do F-score e da área sob a curva ROC (ROC-AUC) nas métricas de avaliação.

O F-score (macro) permitiu avaliar a eficácia dos modelos mesmo perante o desequilíbrio de classes, enquanto a área sob a curva ROC proporcionou uma medida da capacidade de cada modelo distinguir efetivamente entre as classes. No entanto, vale a pena salientar que a adoção de outras métricas, como a precisão e a sensibilidade aplicadas a cada classe, assim como as médias macro, micro e ponderadas destas, pode também justificar-se.

Uma questão importante a considerar na avaliação dos resultados é a representatividade do conjunto de teste utilizado. Neste estudo, o conjunto de teste consistiu de 216 instâncias, correspondendo a 20% do conjunto de dados total. As instâncias foram selecionadas através de um processo de aleatorização com uma semente fixa (implementado no código MATLAB através da instrução “`rng(0);`”), de forma a garantir a reproduzibilidade do estudo.

No entanto, mesmo com a seleção aleatória, devemos considerar a hipótese de o conjunto de teste não representar bem a população de interesse. Se isso acontecer, então certos modelos de classificação podem parecer ter um desempenho melhor

simplesmente porque as características particulares do conjunto de teste favorecem esse modelo. Isso não significa necessariamente que o modelo terá um bom desempenho em dados novos que são representativos da população geral.

Por fim, os resultados deste estudo reafirmam o potencial da combinação de FMG e sEMG para o reconhecimento de gestos da mão, com a finalidade do controlo de próteses. Observa-se que a combinação dessas técnicas melhora substancialmente a robustez dos modelos de Machine Learning treinados para essa tarefa, o que está em linha com as sugestões de estudos anteriores (Citi et al., 2016; Kadkhodayan et al., 2016; Nowak et al., 2017; Radmand et al., 2016; Xiao & Menon, 2017, 2019).

Contudo, é importante considerar as limitações discutidas acima ao interpretar o desempenho dos modelos de classificação. Futuros trabalhos poderiam beneficiar de um maior conjunto de teste para garantir uma maior representatividade e robustez dos resultados.

6 CONCLUSÕES E TRABALHO FUTURO

Este estudo contribui para o campo das próteses mioelétricas ao explorar a implementação e testar a eficiência de um sistema bimodal de aquisição de sinais EMG-FMG para o controlo de uma mão biónica. Os modelos Quadratic SVM, Cubic SVM, Weighted KNN e Fine KNN destacaram-se particularmente em termos de *accuracy*, F-score e a área sob a curva ROC, indicando uma forte capacidade de distinguir entre os diferentes gestos.

Os resultados reforçam a ideia, apoiada por pesquisas anteriores, de que a combinação de EMG e FMG permite aprimorar a eficiência dos modelos de Machine Learning no reconhecimento de gestos. Contudo, foram também evidenciadas limitações importantes. O ajuste de hiperparâmetros, em especial, foi identificado como um fator crítico no desempenho dos modelos.

Durante a implementação, surgiram dificuldades relacionadas à fixação dos sensores FSR e à repetibilidade do posicionamento dos sensores.

Como trabalho futuro, recomenda-se a realização de estudos com conjuntos de teste mais amplos para garantir uma maior representatividade e robustez dos resultados. Uma limitação adicional que deve ser considerada em pesquisas futuras é a variabilidade inerente na execução dos gestos, tanto a nível intraindividual quanto interindividual. Além disso, aprimorar o sistema de fixação dos sensores para torná-lo mais robusto e testar diferentes configurações no posicionamento dos sensores podem ser áreas de foco úteis para melhorar a confiabilidade e a aplicabilidade dos resultados.

REFERÊNCIAS BIBLIOGRÁFICAS

- Aaron Saenz. (2010, Fevereiro 25). *BeBionic Artificial Hand and Wrist – Now With Kung-Fu Grip! (video)*. Singularity Hub.
- Abboudi, R. L., Glass, C. A., Newby, N. A., Flint, J. A., & Craelius, W. (1999). A biomimetic controller for a multifinger prosthesis. *IEEE Transactions on Rehabilitation Engineering*, 7(2), 121–129. <https://doi.org/10.1109/86.769401>
- Belter, J., Segil, J., Dollar, A., & Weir, R. (2013). Mechanical design and performance specifications of anthropomorphic prosthetic hands: A review. *Journal of rehabilitation research and development*, 50, 599–618. <https://doi.org/10.1682/JRRD.2011.10.0188>
- Castellini, C. (2020). Upper Limb Active Prosthetics: An Overview. Em J. Rosen & P. W. Ferguson (Eds.), *Wearable Robotics* (pp. 365–376). Academic Press. <https://doi.org/https://doi.org/10.1016/B978-0-12-814659-0.00019-9>
- Castellini, C., Kõiva, R., Pasluosta, C., Viegas, C., & Eskofier, B. M. (2018). Tactile Myography: An Off-Line Assessment of Able-Bodied Subjects and One Upper-Limb Amputee. *Technologies*, 6(2). <https://doi.org/10.3390/technologies6020038>
- Cavalcanti Garcia, M. A., & Vieira, T. M. M. (2011). Surface electromyography: Why, when and how to use it. *Revista Andaluza de Medicina del Deporte*, 4(1), 17–28. <https://www.elsevier.es/es-revista-revista-andaluza-medicina-del-deporte-284-articulo-surface-electromyography-why-when-how-X1888754611201253>
- Christopher, S., Md Rasedul, I., Assad-Uz-Zaman, M., & Rahman, M. (2018). A Comprehensive Study on EMG Feature Extraction and Classifiers. *Open Access Journal of Biomedical Engineering and its Applications*, 1. <https://doi.org/10.32474/OAJBEB.2018.01.000104>
- Citi, L., Vidoni, R., Menon cmenon, C., Cho, E., Chen, R., Merhi, L.-K., Xiao, Z., Pousett, B., & Menon, C. (2016). *Force Myography to Control Robotic Upper Extremity Prostheses: A Feasibility Study*. 4. <https://doi.org/10.3389/fbioe.2016.00018>
- Cordella, F., Ciancio, A. L., Sacchetti, R., Davalli, A., Cutti, A. G., Guglielmelli, E., & Zollo, L. (2016). Literature Review on Needs of Upper Limb Prosthesis Users. *Frontiers in Neuroscience*, 10. <https://doi.org/10.3389/fnins.2016.00209>
- Day, S. (2002). Important factors in surface EMG measurement. *Bortec Biomedical Ltd Publishers*, 1–17.
- De Luca, C. J. (2002). Surface electromyography: Detection and recording. *Delsys Incorporated*, 10(2), 1–10.
- de Luca, C. J. (2008, Outubro 5). A Practicum on the Use of Surface EMG Signals in Movement Sciences. *Delsys Inc.*

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

- de Luca, C. J., Adam, A., Wotiz, R., Gilmore, L. D., & Nawab, S. H. (2006). Decomposition of Surface EMG Signals. *Journal of Neurophysiology*, 96(3), 1646–1657. <https://doi.org/10.1152/jn.00009.2006>
- Drew Halley. (2009, Março 26). *i-LIMB Revolutionizes the Commercial Prosthetic*. Singularity Hub.
- Duchêne, J., & Goubel, F. (1993). Surface electromyogram during voluntary contraction: processing tools and relation to physiological events. *Critical reviews in biomedical engineering*, 21 4, 313–397.
- Esperança Pina, J. A. (1999). *Anatomia Humana da Locomoção* (2^a ed.). Lidel.
- Esposito, D., Andreozzi, E., Fratini, A., Gargiulo, G. D., Savino, S., Niola, V., & Bifulco, P. (2018). A piezoresistive sensor to measure muscle contraction and mechanomyography. *Sensors (Switzerland)*, 18(8). <https://doi.org/10.3390/s18082553>
- Florimond, V. (2010). Basics of SURFACE ELECTROMYOGRAPHY Applied to Physical Rehabilitation and Biomechanics. *Thought Technology Ltd, Doc Number MAR908(3)*. <https://thoughttechnology.com/content/docs/educational/MAR908-03%20SEMG%20applied%20to%20physical%20rehabilitation%20and%20bio%20mechanics.pdf>
- Follows, A. M. (1987). Electromyographical Analysis of the Extrinsic Muscles of the Long Finger during Pinch Activities. *The Occupational Therapy Journal of Research*, 7(3), 163–180. <https://doi.org/10.1177/153944928700700303>
- Freitas, M. L. B. (2018). *Análise de Características do Sinal EMG para Auxílio em Processos de Classificação de Padrões* [Trabalho de Conclusão de Curso]. Universidade Tecnológica Federal do Paraná.
- Grushko, S., Spurný, T., & Černý, M. (2020). Control Methods for Transradial Prostheses Based on Remnant Muscle Activity and Its Relationship with Proprioceptive Feedback. *Sensors*, 20(17). <https://doi.org/10.3390/s20174883>
- Hayashi, H., Shibasaki, T., & Tsuji, T. (2021). A Neural Network Based on the Johnson SU Translation System and Related Application to Electromyogram Classification. *IEEE Access*, PP, 1. <https://doi.org/10.1109/ACCESS.2021.3126348>
- Heath, M. (2014). The DEKA Arm. *BME* 281.
- Interlink Electronics. (2010). *FSR 402 Data Sheet*. <https://www.trossenrobotics.com/productdocs/2010-10-26-Datasheet-FSR402-Layout2.pdf>
- Jamal, M. Z. (2012). Signal Acquisition Using Surface EMG and Circuit Design Considerations for Robotic Prosthesis. Em G. R. Naik (Ed.), *Computational*

- Intelligence in Electromyography Analysis.* IntechOpen.
<https://doi.org/10.5772/52556>
- Jaquier, N., Connan, M., Castellini, C., & Calinon, S. (2017). Combining Electromyography and Tactile Myography to Improve Hand and Wrist Activity Detection in Prostheses. *Technologies*, 5, 64.
<https://doi.org/10.3390/technologies5040064>
- Jiang, S., Gao, Q., Liu, H., & Shull, P. B. (2020). A novel, co-located EMG-FMG-sensing wearable armband for hand gesture recognition. *Sensors and Actuators A: Physical*, 301, 111738.
<https://doi.org/https://doi.org/10.1016/j.sna.2019.111738>
- Kadkhodayan, A., Jiang, X., & Menon, C. (2016). Continuous Prediction of Finger Movements Using Force Myography. *Journal of Medical and Biological Engineering*, 36(4), 594–604. <https://doi.org/10.1007/s40846-016-0151-y>
- Kamen, G., & Gabriel, D. A. (viaf)103384635. (2010). *Essentials of electromyography*. Human Kinetics. <http://lib.ugent.be/catalog/rug01:001701003>
- Konrad, P. (2005). The ABC of EMG : A Practical Introduction to Kinesiological Electromyography. Em Noraxon U.S.A. Inc. Noraxon U.S.A. Inc.
- Kuiken, T. A., Lowery, M., & Stoykov, N. (2003). The effect of subcutaneous fat on myoelectric signal amplitude and cross-talk. *Prosthetics and orthotics international*, 27, 48–54. <https://doi.org/10.3109/03093640309167976>
- Long, C., Conrad, P. W., Hall, E. A., & Furler, S. L. (1970). Intrinsic-extrinsic muscle control of the hand in power grip and precision handling. An electromyographic study. *The Journal of bone and joint surgery. American volume*, 52 5, 853–867.
- Marieb, E., Wilhelm, P., & Mallatt, J. (2014). *Anatomia Humana* (7^a ed.). Pearson Education do Brasil.
- McIntosh, J., McNeill, C., Fraser, M., Kerber, F., Löchtefeld, M., & Krüger, A. (2016). EMPress: Practical Hand Gesture Classification with Wrist-Mounted EMG and Pressure Sensing. 2332–2342. <https://doi.org/10.1145/2858036.2858093>
- McManus, L., de Vito, G., & Lowery, M. M. (2020). Analysis and Biophysics of Surface EMG for Physiotherapists and Kinesiologists: Toward a Common Language With Rehabilitation Engineers. *Frontiers in Neurology*, 11. <https://doi.org/10.3389/fneur.2020.576729>
- Merletti, R. (2012). Generation, Propagation, and Extinction of Single-Fiber and Motor Unit Action Potentials. Em *Atlas of Muscle Innervation Zones: Understanding Surface Electromyography and Its Applications* (pp. 21–38). Springer Milan.
https://doi.org/10.1007/978-88-470-2463-2_3

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

- Merletti, R., & Cerone, G. L. (2020). Tutorial. Surface EMG detection, conditioning and pre-processing: Best practices. *Journal of Electromyography and Kinesiology*, 54, 102440. <https://doi.org/10.1016/J.JELEKIN.2020.102440>
- Mobius Bionics LLC. (2019). *LUKE Arm System*.
<https://www.mobiusbionics.com/wp-content/uploads/2019/09/Mobius-Bionics-LUKE-Product-Spec-Sheet.pdf>
- Moore, K., Dalley, A., & Agur, A. (2017). *Clinically Oriented Anatomy* (8.^a ed.). Wolters Kluwer (Lippincott Williams & Wilkins).
- Nazmi, N., Abdul Rahman, M. A., Yamamoto, S.-I., Ahmad, S. A., Zamzuri, H., & Mazlan, S. A. (2016). A Review of Classification Techniques of EMG Signals during Isotonic and Isometric Contractions. *Sensors (Basel, Switzerland)*, 16(8), 1304. <https://doi.org/10.3390/s16081304>
- Nowak, M., Eiband, T., & Castellini, C. (2017). Multi-modal myocontrol: Testing combined force- and electromyography. *IEEE ... International Conference on Rehabilitation Robotics : [proceedings]*, 2017, 1364–1368.
<https://doi.org/10.1109/ICORR.2017.8009438>
- Open Bionics. (sem data). *Hero Arm User Guide*. Obtido 18 de Julho de 2023, de <https://openbionics.com/hero-arm-user-guide/>
- Ortolan, R. L. (2002). *Estudo e Avaliação de Técnicas de Processamento do Sinal Mioelétrico para o Controle de Sistemas de Reabilitação* [Dissertação de Mestrado]. Universidade de São Paulo.
- Oskoei, M. A., & Hu, H. (2008). Support Vector Machine-Based Classification Scheme for Myoelectric Control Applied to Upper Limb. *IEEE Transactions on Biomedical Engineering*, 55(8), 1956–1965.
<https://doi.org/10.1109/TBME.2008.919734>
- Petch, J., Di, S., & Nelson, W. (2022). Opening the Black Box: The Promise and Limitations of Explainable Machine Learning in Cardiology. *Canadian Journal of Cardiology*, 38(2), 204–213.
<https://doi.org/https://doi.org/10.1016/j.cjca.2021.09.004>
- Phinyomark, A., Phukpattaranont, P., & Limsakul, C. (2012). Feature Reduction and Selection for EMG Signal Classification. *Expert Systems with Applications*, 39, 7420–7431. <https://doi.org/10.1016/j.eswa.2012.01.102>
- PLUX Wireless Biosignals, S. A. (2016). *BITalino (r)evolution Plugged Kit Data Sheet*.
<https://support.pluxbiosignals.com/wp-content/uploads/2021/11/revolution-bitalino-plugged-kit-datasheet.pdf>
- PLUX Wireless Biosignals, S. A. (2020). *BITalino Electromyography (EMG) User Manual*.
<https://www.bitalino.com/storage/uploads/media/electromyography-emg-user-manual.pdf>

- Radmand, A., Scheme, E., & Englehart, K. (2014). High-resolution muscle pressure mapping for upper-limb prosthetic control. *Proceedings of the MEC-Myoelectric Control Symposium*, 189–193.
- Radmand, A., Scheme, E., & Englehart, K. (2016). High-density force myography: A possible alternative for upper-limb prosthetic control. *Journal of Rehabilitation Research and Development*, 53, 443–456.
<https://doi.org/10.1682/JRRD.2015.03.0041>
- Raez, M. B. I., Hussain, M. S., & Mohd-Yasin, F. (2006). Techniques of EMG signal analysis: detection, processing, classification and applications. *Biological Procedures Online*, 8, 11–35. <https://doi.org/10.1251/bpo115>
- Rafiee, J., Rafiee, M. A., Yavari, F., & Schoen, M. P. (2011). Feature extraction of forearm EMG signals for prosthetics. *Expert Systems with Applications*, 38(4), 4058–4067. <https://doi.org/https://doi.org/10.1016/j.eswa.2010.09.068>
- Rodrigues, S. (2021). *Open Source Bionic Hand – Implementação do controlo da mão em tempo real* [Relatório de Trabalho de Projeto]. Instituto Superior de Engenharia de Coimbra.
- Sarmiento Vela, J. F. (2013). *Protocolos e Técnicas de Análise de Sinais sEMG Aplicados à Avaliação Motora e Robótica* [Tese de Doutoramento]. Universidade Federal do Espírito Santo.
- Seeley, R., Stephens, T., & Tate, P. (2005). *Anatomia & Fisiologia* (6^a Edição). Lusodidacta.
- Seiler III, J. G. (2002). *Essentials of Hand Surgery*. Lippincott Williams & Wilkins.
- Silva, J. R. F. dos S. (2018). *Classificação de gestos a partir de dados EMG* [Dissertação de Mestrado]. Coimbra.
- Simão, M., Mendes, N., Gibaru, O., & Neto, P. (2019). A Review on Electromyography Decoding and Pattern Recognition for Human-Machine Interaction. *IEEE Access*, 7, 39564–39582.
<https://doi.org/10.1109/ACCESS.2019.2906584>
- Thakor, N. (2014). Biopotentials and Electrophysiology Measurement. Em J. Webster & H. Eren (Eds.), *Measurement, Instrumentation, and Sensors Handbook* (2.^a ed.). CRC Press. <https://doi.org/https://doi.org/10.1201/b15664>
- VanPutte, C., Regan, J., & Russo, A. (2016). *Anatomia e Fisiologia de Seeley* (10.^a ed.). Mc Graw-Hill.
- Wikipedia contributors. (2023a). *Hyperparameter optimization — Wikipedia, The Free Encyclopedia*. https://en.wikipedia.org/w/index.php?title=Hyperparameter_optimization&oldid=1165646824

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

- Wikipedia contributors. (2023b). *K-nearest neighbors algorithm* — Wikipedia, The Free Encyclopedia. https://en.wikipedia.org/w/index.php?title=K-nearest_neighbors_algorithm&oldid=1163707353
- Wikipedia contributors. (2023c). *MATLAB* — Wikipedia, The Free Encyclopedia. <https://en.wikipedia.org/w/index.php?title=MATLAB&oldid=1166260040>
- Wikipedia contributors. (2023d). *Michelangelo Hand* — Wikipedia, The Free Encyclopedia. https://en.wikipedia.org/w/index.php?title=Michelangelo_Hand&oldid=1143334463
- Wikipedia contributors. (2023e). *Pattern recognition* — Wikipedia, The Free Encyclopedia. https://en.wikipedia.org/w/index.php?title=Pattern_recognition&oldid=1164650160
- Wikipedia contributors. (2023f). *Receiver operating characteristic* — Wikipedia, The Free Encyclopedia. https://en.wikipedia.org/w/index.php?title=Receiver_operating_characteristic&oldid=1166530276
- Wikipedia contributors. (2023g). *Wavelet* — Wikipedia, The Free Encyclopedia. <https://en.wikipedia.org/w/index.php?title=Wavelet&oldid=1160233769>
- Xiao, Z. G., & Menon, C. (2017). Performance of Forearm FMG and sEMG for Estimating Elbow, Forearm and Wrist Positions. *Journal of Bionic Engineering*, 14(2), 284–295. [https://doi.org/https://doi.org/10.1016/S1672-6529\(16\)60398-0](https://doi.org/https://doi.org/10.1016/S1672-6529(16)60398-0)
- Xiao, Z. G., & Menon, C. (2019). A Review of Force Myography Research and Development. *Sensors*, 19(20). <https://doi.org/10.3390/s19204557>

Nuno Manuel Lourenço Pires

ANEXOS

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

Anexo A – Póster das Jornadas de Biomédica

Instituto Superior de Engenharia
Politécnico de Coimbra

Eletromiografia assistida por FMG no reconhecimento de gestos da mão

Nuno Pires; Milton Macedo, PhD (mpmacedo@isec.pt)
Instituto Superior de Engenharia de Coimbra

Introdução

As próteses mioelétricas de membro superior, também chamadas de mãos biónicas, são dispositivos eletromecânicos que são acoplados ao membro residual de indivíduos amputados e que tentam replicar a funcionalidade da mão humana.

Os modelos de mão biónica comerciais usam sensores eletromiográficos de superfície (EMG) para captação da atividade elétrica produzida aquando da ativação dos remanescentes musculares. Contudo, este é um método de deteção cuja eficácia é suscetível a ruído eletromagnético externo, fadiga muscular, ou alterações de impedância na interface sensor-pele.

Este estudo implementa e avalia a viabilidade de um sistema bimodal para aquisição de sinais EMG/FMG destinado ao controlo de uma mão biónica open source. Os resultados preliminares apontam para ganhos relevantes na eficácia de classificação dos gestos, em linha com conclusões outros estudos [1] [2].

Metodologia

Neste estudo, participam 5 indivíduos saudáveis. Os sinais EMG e FMG foram recolhidos simultaneamente de cada participante, utilizando a plataforma BITalino com 4 canais de aquisição: 2 para EMG e 2 para FMG (Figura 1a). Um par de sensores EMG-FMG foi colocado no grupo muscular extensor do antebraço e o outro no grupo muscular flexor (Figura 1b).



Figura 1-a) Setup de aquisição de sinais; b) Posicionamento dos sensores.

O BITalino transmite os dados via Bluetooth para um PC, onde são visualizados em tempo real e armazenados para processamento posterior usando o software OpenSignals. Os participantes foram instruídos a executar seis gestos: abertura, fecho, *pinch*, *point*, e *thumbs-up*. Cada arquivo de dados recolhido contém aproximadamente dez ativações de cada gesto. Os dados recolhidos foram submetidos a um pré-processamento offline no MATLAB, após o qual se fez a deteção dos momentos de onset e offset. A partir dos sinais EMG e FMG de cada grupo muscular, extraíram-se características relevantes que serviriam de entrada para o treino de modelos de Machine Learning, através do Classification Learner do MATLAB, com o objetivo de prever a execução de cada gesto.

O Sinal EMG

O sinal EMG é a expressão elétrica da atividade muscular, capturada por elétrodos de superfície colocados na pele sobre o músculo em estudo.

A amplitude do sinal EMG, que é de natureza estocástica (aleatória), é influenciada pela força da contração muscular e geralmente varia de 0 a 10 mV pico-a-pico, ou de 0 a 1,5 mV RMS. O sinal EMG é particularmente útil na faixa de frequências de 0 a 500 Hz, com a energia dominante no intervalo 50-150 Hz. Esta característica do sinal é ilustrada na Figura 2, que mostra espectros de densidade de potência de sinais EMG de diferentes gestos da mão.

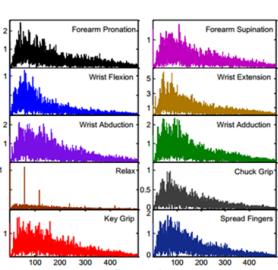


Figura 2 – Espectros de densidade de potência de sinais EMG em gestos da mão [3].

O sinal EMG é uma ferramenta amplamente utilizada na deteção da intenção do movimento em aplicações de próteses biónicas comerciais. No entanto, a busca por informações adicionais sobre a atividade muscular tem motivado a exploração de técnicas complementares, como a Force Myography (FMG).

Coimbra Engineering Academy
Instituto Superior de Engenharia de Coimbra

Force Myography

A Force Myography, ou miografia de força, é uma técnica não-invasiva que faz uso de sensores de pressão colocados na pele acima dos músculos para captar mudanças de pressão e volume associadas à ativação e desativação de grupos musculares superficiais. Ao invés de medir a atividade elétrica muscular como o EMG, a FMG regista as alterações mecânicas, captando assim informações distintas, que podem ser valiosas no contexto das próteses biónicas.

Embora a FMG apresente benefícios como robustez perante mudanças de impedância da pele e sudorese, e menor sensibilidade ao posicionamento do sensor, enfrenta desafios como a sensibilidade a movimentos não intencionais e interferências externas.

Processamento dos Sinais

Conforme ilustrado na Figura 3, os sinais EMG e FMG são inicialmente adquiridos pelo BITalino, onde são submetidos a um pré-processamento básico, que inclui amplificação e filtragem inicial.

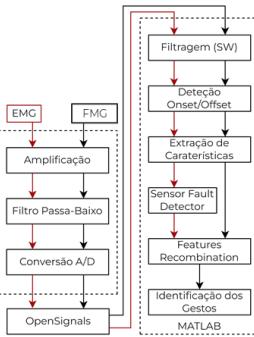


Figura 3 – Etapas do processamento dos sinais EMG e FMG.

Em seguida, os sinais são encaminhados para processamento offline em MATLAB. Aqui, são realizadas operações adicionais de denoising e filtragem passa-banda para manter apenas as frequências relevantes. O offset do sinal é também removido.

Após o pré-processamento, os dados entram na fase de extração de características, onde se destacam os aspetos mais informativos dos sinais para a discriminação dos gestos. Isso envolve a deteção de onsets e offsets do sinal para identificar os períodos de ativação muscular.

Por fim, cada vetor de características é rotulado com o gesto correspondente (que consta no nome do ficheiro de dados) e os dados são preparados para a classificação. Estes dados são então usados para treinar um modelo de classificação, que identifica os gestos com base nas características extraídas dos sinais.

Resultados Preliminares

Os resultados preliminares do nosso estudo mostram avanços significativos no desenvolvimento do nosso sistema de reconhecimento de gestos. Treinámos 31 classificadores e podemos destacar o desempenho de seis: Linear Discriminant, Quadratic SVM, Cubic SVM e três arquiteturas de Redes Neurais (Narrow, Medium e Wide). Esses modelos foram treinados com diferentes métodos de seleção de características - ANOVA, ReliefF e Kruskal Wallis - e variando a percentagem de características selecionadas (75, 50 ou 25%).

O Linear Discriminant e os classificadores Quadratic SVM e Cubic SVM demonstraram resultados consistentes, com pouco declínio na precisão quando se diminui o percentil das características selecionadas. Em particular, o Linear Discriminant mostrou um bom equilíbrio entre precisão de validação e de teste, destacando-se com 100% das características, alcançando precisões de validação e teste de 91,7% e 93,8%, respectivamente. Por outro lado, os classificadores baseados em redes neurais apresentaram uma variabilidade maior nos seus resultados, indicando uma sensibilidade à seleção de características. Em particular, a rede neural "wide" apresentou um excelente desempenho sem seleção de características, alcançando precisões de validação e teste de 95,1% e 93,8%, respectivamente.

Literatura Citada

- [1] Esposito, D., Andreozzi, E., Fratini, A., Gargiulo, G. D., Savino, S., Niola, V., & Bifulco, P. (2018). A piezoresistive sensor to measure muscle contraction and mechanomyography. Sensors (Switzerland), 18(8).
- [2] Jiang, S., Gao, Q., Liu, H., & Shull, P. B. (2020). A novel, co-located EMG-FMG-sensing wearable armband for hand gesture recognition. Sensors and Actuators A: Physical, 301, 111738.
- [3] J. Rafiee, M. A. Rafiee, F. Yavari, and M. P. Schoen, "Feature extraction of forearm EMG signals for prosthetics," Expert Systems with Applications, vol. 38, no. 4, pp. 4058–4067, 2011.

63

Anexo B – Rotina MATLAB: main.m

```
close all; clear; clc

% Get list of all .txt files in the current folder
files = dir('*.*txt');
n_files = length(files);

% Initialize arrays to store features
features_abertura = [];
features_fecho = [];
features_ok = [];
features_point = [];
features_pinch = [];

% Define parameters for the onsetting function
sz = 325; % Set the window size for moving average calculation
threshold_size = 2750;
a = 0.2;
fs = 1000; % Sampling frequency

% Define a tolerance window for finding matching activations
tolerance_window = 500;

for i = 1:n_files
    % Get the file name of the current file
    file_name = files(i).name;

    % Load data from the file into a matrix
    data = readmatrix(file_name);

    % Extract EMG signals from the data matrix
    emg_A3 = data(:, 6); % EMG signal for the extensor muscle group
    emg_A4 = data(:, 7); % EMG signal for the flexor muscle group

    % Extract FMG signals from the data matrix
    fmg_A1 = data(:, 8); % FMG signal for the extensor muscle group
    fmg_A2 = data(:, 9); % FMG signal for the flexor muscle group

    % Apply a band-pass filter to the EMG signals (20 to 500 Hz)
    filter_object = filtbpass20500;
    emg_A3_filtered = filter(filter_object, emg_A3);
    emg_A4_filtered = filter(filter_object, emg_A4);

    % Denoise the filtered EMG signals using wavelet denoising
    emg_A3_denoised = wdenoise(emg_A3_filtered, 4);
    emg_A4_denoised = wdenoise(emg_A4_filtered, 4);

    % Remove the baseline from the filtered EMG signals
    emg_A3_processed = emg_A3_denoised - mean(emg_A3_denoised);
    emg_A4_processed = emg_A4_denoised - mean(emg_A4_denoised);

    % Call onsetting function and store the preprocessed signals and moving
    averages
    [onsets_A3, offsets_A3, mavg_emg_A3] = onsetting(emg_A3_processed, sz,
threshold_size, a);
    [onsets_A4, offsets_A4, mavg_emg_A4] = onsetting(emg_A4_processed, sz,
threshold_size, a);
```

*Reconhecimento de gestos através da implementação de sistema bimodal de aquisição
de sinais EMG e FMG*

```
% Call the plot_signals function to visualize the signals
figure;
plot_signals(fmg_A1, fmg_A2, emg_A3_processed, emg_A4_processed, onsets_A3,
offsets_A3, onsets_A4, offsets_A4, mavg_emg_A3, mavg_emg_A4, file_name, fs);

% Find matching onsets and offsets within the tolerance window
matching_activations = [];
i_onset_A3 = 1;
j_onset_A4 = 1;

% Loop through onsets and find matches within the tolerance window
while i_onset_A3 <= length(onsets_A3) && j_onset_A4 <= length(onsets_A4)
    % Compare the difference between onsets to the tolerance window
    if abs(onsets_A3(i_onset_A3) - onsets_A4(j_onset_A4)) <= tolerance_window
        found_match = false;
        for i_offset = i_onset_A3:length(offsets_A3)
            for j_offset = j_onset_A4:length(offsets_A4)
                % Check if the difference between offsets is within the
tolerance window
                if abs(offsets_A3(i_offset) - offsets_A4(j_offset)) <=
tolerance_window
                    % Store the matching onsets and offsets
                    matching_activations = [matching_activations;
onsets_A3(i_onset_A3), onsets_A4(j_onset_A4), offsets_A3(i_offset),
offsets_A4(j_offset)];
                    found_match = true;
                    break;
                end
            end
            if found_match
                break;
            end
        end
        i_onset_A3 = i_onset_A3 + 1;
        j_onset_A4 = j_onset_A4 + 1;
        % If the difference between onsets is not within the tolerance
        % window, move to the next onset
        elseif onsets_A3(i_onset_A3) < onsets_A4(j_onset_A4)
            i_onset_A3 = i_onset_A3 + 1;
        else
            j_onset_A4 = j_onset_A4 + 1;
        end
    end
end

% Extract features for each matched onset and store as separate instances
for idx = 1:size(matching_activations, 1)
    onset_A3 = matching_activations(idx, 1);
    onset_A4 = matching_activations(idx, 2);
    offset_A3 = matching_activations(idx, 3);
    offset_A4 = matching_activations(idx, 4);

    % Extract features from both EMG and FMG signals within the window
    features_A1_A3 = [extract_fmg_features(fmg_A1, onset_A3, offset_A3), ...
                     extract_emg_features(emg_A3_processed, onset_A3, offset_A3)];
    features_A2_A4 = [extract_fmg_features(fmg_A2, onset_A4, offset_A4), ...
                     extract_emg_features(emg_A4_processed, onset_A4, offset_A4)];

    % Combine features from both muscle groups
```

```

combined_features = [features_A1_A3, features_A2_A4];

% Append combined features to respective arrays based on the gesture
if contains(file_name, 'abrir')
    features_abertura = [features_abertura; combined_features];
elseif contains(file_name, 'fechar')
    features_fecho = [features_fecho; combined_features];
elseif contains(file_name, 'ok')
    features_ok = [features_ok; combined_features];
elseif contains(file_name, 'point')
    features_point = [features_point; combined_features];
elseif contains(file_name, 'pinch')
    features_pinch = [features_pinch; combined_features];
end
end
end

% Combine all feature arrays
all_features = [features_abertura; features_fecho; features_ok; features_point;
features_pinch];

% Create a label array for each gesture type
labels_abertura = repmat("abrir", size(features_abertura, 1), 1);
% Creates a string array of labels 'abrir'.
% size(features_abertura, 1) returns the number of rows ('1') in the
% features_abertura matrix.
% repmat Replicate and tile an array.
%      B = repmat(A,M,N) or B = repmat(A,[M,N]) creates a large matrix B
%      consisting of an M-by-N tiling of copies of A. If A is a matrix,
%      the size of B is [size(A,1)*M, size(A,2)*N].
labels_fecho = repmat("fechar", size(features_fecho, 1), 1);
labels_ok = repmat("ok", size(features_ok, 1), 1);
labels_point = repmat("point", size(features_point, 1), 1);
labels_pinch = repmat("pinch", size(features_pinch, 1), 1);

% Combine all label arrays into one.
all_labels = [labels_abertura; labels_fecho; labels_ok; labels_point;
labels_pinch];

% Convert the combined features and labels into a table format
data_table = array2table(all_features);
data_table.Labels = all_labels;

% Define feature names for both FMG and EMG signals
fmg_feature_names = ["mean_fmg", "rms_fmg", "std_fmg", "median_fmg", "wl_fmg",
"ssc_fmg"];
emg_feature_names = ["rms", "mav", "sd", "iqr", "wl", "ssc", "iemg", ...
"kurt", "log", "mnf", "pkf", "mnpssd"];

% Combine feature names for extensor and flexor muscle groups
combined_feature_names = [fmg_feature_names + "_Extensor", emg_feature_names +
"_Extensor", ...
fmg_feature_names + "_Flexor", emg_feature_names + "_Flexor"];

% Assign feature names to the table columns
data_table.Properties.VariableNames = [combined_feature_names, "labels"];

% Shuffle the data_table rows to ensure random distribution before splitting
rng(0); % For reproducibility

```

*Reconhecimento de gestos através da implementação de sistema bimodal de aquisição
de sinais EMG e FMG*

```
num_rows = height(data_table);
shuffled_data_table = data_table(randperm(num_rows), :);

% Split the shuffled dataset into training and testing sets
train_size = round(0.80 * num_rows); % Size of the training dataset
train_data = shuffled_data_table(1:train_size, :);
test_data = shuffled_data_table(train_size+1:end, :);
```

Anexo C – Rotina MATLAB: onsetting.m

```

function [onsets, offsets, mavg_emg] = onsetting(onda, sz, threshold_size, a)
    % Full-wave rectification
    fwlo = abs(onda);

    % Moving average for calculating the test function
    tf_mvgav = conv2(fwlo, ones(sz,1)/sz, 'valid'); % Return only parts of the
    convolution that are computed without zero-padded edges

    % Moving average with 'same' option (the output of the convolution has
    % the same size as the input signal)
    mavg_emg = conv(fwlo, ones(sz, 1) / sz, 'same');

    % Moving average for calculating the adaptive threshold
    threshold_mvgav = conv2(fwlo, ones(threshold_size,1)/threshold_size, 'valid');
    % conv also works, convolution of 2 1-D arrays

    % Threshold for the median averages
    threshold = a*mean(tf_mvgav) + std(tf_mvgav); % Sets the onset detection
    threshold as a percentage of the mean (determined by 'a') plus the data's standard
    deviation.

    onset_time_list = [];
    offset_time_list = [];
    onset = 0;

    ignore_first_samples = 1000; % Set a fixed value for the number of samples to
    ignore at the beginning, e.g., 1000 samples
    min_distance = 1000; % Set a fixed value for min_distance, e.g., 3000 samples,
    for the onset-onset distance

    for k=1:length(threshold_mvgav)
        if k <= ignore_first_samples
            continue;
        end
        if onset==1 % An onset was previously detected and we are looking for the
        offset time, applying the same criteria
            if tf_mvgav(k)< threshold_mvgav(k) && tf_mvgav(k) < threshold
                offset_time_list=[offset_time_list k];
                onset=0; % The offset has been detected, and we can look for
                another activation
            end
        else
            % We only look for another onset if a previous offset was
            % detected
            if tf_mvgav(k) >= threshold_mvgav(k) && tf_mvgav(k) >= threshold
                % Check if the minimum distance requirement is satisfied.
                if isempty(onset_time_list) || (k - onset_time_list(end)) >
                min_distance)
                    % The first index of the sliding window is used as an
                    % estimate for the onset time (simple post-processor
                    onset_time_list=[onset_time_list k];
                    onset = 1;
                end
            end
        end
    end
end

```

*Reconhecimento de gestos através da implementação de sistema bimodal de aquisição
de sinais EMG e FMG*

```
% Adjust indices because of moving average
onset_time_list=onset_time_list+round(sz/2);
offset_time_list=offset_time_list+round(sz/2);

% To avoid indices of different dimensions data is discarded in
% whichever array is longer
if(length(offset_time_list)>length(onset_time_list))
    offset_time_list=offset_time_list(:,1:end-1);
end
if(length(onset_time_list)>length(offset_time_list) &&
onset_time_list(end)>offset_time_list(end))
    onset_time_list=onset_time_list(:,1:end-1);
end

% Only periods of activation above 650 miliseconds are considered to
% rule out false activations
d=offset_time_list-onset_time_list;
b=d>650;
onsets=onset_time_list(b);
offsets=offset_time_list(b);
end
```

Anexo D – Rotina MATLAB: extract_emg_features.m

```
function features = extract_emg_features(X, onsets, offsets)
n_windows = length(onsets);
features = [];

for j = 1:n_windows
    wave = X(onsets(j):offsets(j));

    % Time-domain features:
    % Mean Absolute Value (MAV)
    % Root Mean Square (RMS)
    % Standard deviation (SD)
    % Interquartile range (IQR)
    % Waveform Length (WL)
    % Zero Crossings (ZC)
    % Slope Sign Changes (SSC)
    % Willison Amplitude (WAMP)
    % Integrated EMG (IEMG)
    % Kurtosis (KURT)
    % Lod Detector (LOG)

    RMS = rms(wave);
    MAV = mean(abs(wave));
    SD = std(wave);
    IQR = iqr(wave);
    WL = find_waveform_length(wave);
    SSC = find_slopSign(wave, 0.015);
    IEMG = find_integratedEMG(wave);
    KURT = kurtosis(wave);
    LOG = find_log_detector(wave);

    % Frequency-domain features:
    % Mean Frequency (MNF)
    % Power Spectral Density (PSD)
    % Peak Frequency (PKF)
    % Mean Power Spectral Density (MNPSD)

    MNF = meanfreq(wave);
    [PSD, F] = pwelch(wave, [], [], [], 1000); % F is the vector of
    frequencies (in hertz) at which the PSD is estimated
    [~, maxIndex] = max(PSD);
    PKF = F(maxIndex);
    MNPSD = mean(PSD);

    % Add features to the output array
    features(j, :) = [RMS MAV SD IQR WL SSC IEMG KURT LOG MNF PKF MNPSD];
end
end
```

Anexo E – Rotina MATLAB: extract_fmg_features.m

```
function features = extract_fmg_features(fmg, onsets, offsets)
n_windows = length(onsets);
features = [];

for j = 1:n_windows
    wave = fmg(onsets(j):offsets(j));

    mean_fmg = mean(wave);
    rms_fmg = rms(wave);
    std_fmg = std(wave);
    median_fmg = median(wave);
    wl_fmg = find_waveform_length(wave);
    ssc_fmg = find_slopeSign(wave, 0.015);

    features(j, :) = [mean_fmg, rms_fmg, std_fmg, median_fmg, wl_fmg, ssc_fmg];
end
end
```

Anexo F – Seleção de caraterísticas

VALIDAÇÃO	mRMR (30)			mRMR (24)			mRMR (18)			Chi2 (30)			Chi2 (24)			Chi2 (18)			ReliefF (30)			ReliefF (24)			ReliefF (18)			ANOVA (30)			ANOVA (24)			ANOVA (18)			Kruskal (30)			Kruskal (24)			Kruskal (18)		
Fine Tree	72,57	71,30	72,69	72,22	71,30	73,38	72,69	71,18	71,64	73,84	73,03	74,42	73,26	70,49	72,57	68,63																													
Medium Tree	61,11	63,19	62,27	61,92	63,08	63,77	62,85	62,73	61,81	65,97	62,96	65,51	64,81	63,66	63,77	63,89																													
Coarse Tree	48,03	48,38	48,38	48,26	48,73	48,73	48,96	48,26	48,26	48,26	48,15	48,61	48,61	49,42	49,42	49,42	49,42																												
Linear Discriminant	72,34	70,60	68,63	66,32	71,64	67,01	65,28	71,64	69,56	64,70	71,30	67,94	62,04	70,72	67,01	62,27																													
Quadratic Discriminant	83,33	83,33	81,13	80,21	82,87	82,06	80,44	83,10	82,75	82,64	82,87	81,48	71,18	81,94	79,98	67,94																													
Efficient Logistic Regression	35,30	36,34	39,70	38,54	34,72	37,27	56,48	37,04	36,81	66,20	31,71	31,13	27,89	33,56	37,27	42,71																													
Efficient Linear SVM	62,85	59,38	57,64	52,55	55,56	51,04	59,49	61,81	57,29	62,73	52,66	51,39	50,81	53,59	50,35	51,62																													
Gaussian Naïve Bayes	55,21	56,83	57,64	57,99	56,90	56,25	50,69	53,59	52,20	57,64	56,37	54,28	54,98	56,60	57,06	55,90																													
Kernel Naïve Bayes	63,54	62,27	62,27	62,62	61,92	62,04	60,07	63,08	61,57	61,23	62,38	59,38	55,67	63,08	60,42	57,52																													
Linear SVM	72,45	71,76	71,41	71,41	71,41	70,72	68,40	70,60	68,40	73,26	69,79	62,62	72,69	71,76	65,51																														
Quadratic SVM	90,05	87,73	86,69	85,88	87,50	87,73	85,65	89,00	87,38	86,69	88,19	86,92	78,59	87,73	86,11	80,67																													
Cubic SVM	89,35	88,66	88,31	87,62	89,35	86,34	86,23	89,00	87,96	88,08	89,58	88,66	83,45	88,43	86,92	79,86																													
Fine Gaussian SVM	76,50	75,93	73,84	76,16	78,36	80,56	82,29	81,13	79,63	84,03	78,59	79,40	79,28	78,24	76,16	79,86																													
Medium Gaussian SVM	86,92	85,53	84,49	84,61	84,14	83,80	84,61	85,53	86,23	85,88	86,23	85,19	79,75	84,38	83,45	78,36																													
Coarse Gaussian SVM	64,35	63,66	64,00	64,70	65,39	64,35	60,65	64,24	64,12	63,89	64,24	63,08	59,38	63,54	62,73	59,26																													
Fine KNN	88,19	87,04	86,81	86,81	88,77	87,50	86,23	90,16	87,15	87,85	89,70	89,58	84,72	88,89	86,57	82,99																													
Medium KNN	82,75	82,06	83,33	82,64	82,64	82,18	81,83	83,68	82,99	83,91	82,64	83,68	81,71	81,48	82,06	77,55																													
Coarse KNN	60,53	58,56	60,42	58,68	60,53	60,19	59,03	60,76	59,95	60,88	61,34	61,34	59,03	60,07	60,65	61,00																													
Cosine KNN	81,02	81,25	81,60	80,44	79,63	79,28	78,24	82,99	80,90	81,71	81,02	81,25	77,55	80,32	79,51	74,19																													
Cubic KNN	81,02	79,98	80,79	80,90	80,21	81,60	80,67	82,41	82,52	82,75	81,83	81,94	80,79	80,44	78,82	77,66																													
Weighted KNN	87,27	86,11	86,57	85,30	86,57	86,81	85,53	87,15	86,81	87,73	86,81	87,04	83,80	86,69	85,19	82,99																													
Boosted Trees	74,19	76,83	74,65	75,00	74,77	73,26	72,34	74,19	74,54	73,73	73,38	71,76	73,84	72,80	72,22																														
Bagged Trees	83,91	85,65	85,65	83,68	83,45	82,52	83,45	84,38	82,99	83,80	83,33	85,19	82,06	84,49	83,80	79,05																													
Subspace Discriminant	70,60	67,82	64,93	61,92	69,21	65,63	60,88	68,63	66,32	62,15	68,63	65,16	60,19	68,63	65,16	60,88																													
Subspace KNN	66,09	63,66	62,50	60,30	57,06	56,48	64,70	61,34	58,33	68,29	58,56	56,13	53,47	60,30	59,03	58,33																													
RUSBoosted Trees	70,37	73,03	72,80	72,92	70,60	68,98	69,33	70,25	68,52	68,87	69,91	68,52	68,75	70,49	68,87	70,14																													
Narrow Neural Network	81,13	80,44	79,98	77,55	78,94	76,27	78,94	81,94	81,60	79,28	78,47	79,51	74,77	77,55	77,89	74,07																													
Medium Neural Networks	84,61	85,53	81,71	85,65	84,26	83,91	82,64	84,14	83,22	83,53	83,80	82,99	75,93	83,10	83,91	78,94																													
Wide Neural Network	87,15	86,00	86,23	83,68	85,42	85,30	85,65	84,26	85,88	86,00	86,46	85,07	81,60	85,76	85,30	87,70																													
Bilayered Neural Network	81,60	80,67	79,86	77,20	78,47	75,35	78,01	80,32	80,90	80,79	79,98	81,13	75,46	79,75	78,59	71,88																													
Trilayered Neural Network	77,78	78,24	76,04	80,56	79,98	77,20	78,36	79,17	79,86	77,43	80,55	79,05	74,54	78,47	78,36	74,31																													
SVM Kernel	63,08	59,38	50,58	48,73	52,31	42,01	54,05	62,04	45,49	66,67	51,85	51,27	39,93	52,31	42,01	50,46																													
Logistic Regression Kernel	58,22	56,48	49,07	45,83	48,03	39,81	53,01	56,71	40,51	62,38	50,53	48,84	36,34	51,27	41,32	48,50																													

Reconhecimento de gestos através da implementação de sistema bimodal de aquisição de sinais EMG e FMG

TESTE	None	MARTR (30)	MARTR (18)	Chi2 (30)	Chi2 (24)	Chi2 (18)	ReliefF (30)	ReliefF (24)	ANOVA (30)	ANOVA (24)	ANOVA (18)	Kruskal (30)	Kruskal (24)	Kruskal (18)		
Fine Tree	74.07	75.46	75.93	73.61	75.46	73.61	73.15	75.00	76.39	72.69	74.07	70.37	72.69	77.31	68.98	
Medium Tree	56.94	61.11	61.11	56.94	61.11	61.11	56.94	58.33	61.57	56.94	54.17	56.94	61.11	55.56		
Coarse Tree	43.06	43.06	43.06	43.06	43.06	43.06	43.06	43.06	43.06	43.06	43.06	43.06	43.06	43.06		
Linear Discriminant	75.46	71.30	66.20	62.96	69.91	69.44	65.74	72.22	68.06	63.89	70.83	69.44	59.72	70.83	60.65	
Quadratic Discriminant	83.80	80.56	77.31	81.94	82.87	78.70	81.48	81.02	81.94	81.02	82.87	66.20	81.48	77.31	65.28	
Efficient Logistic Regression	31.02	30.56	34.26	32.87	29.63	29.63	70.83	32.41	31.48	70.83	30.56	30.09	26.39	27.78	31.48	
Efficient Linear SVM	68.06	64.35	61.11	60.65	56.02	53.70	65.28	55.56	60.19	66.67	50.00	53.70	46.76	54.17	52.78	
Gaussian Naïve Bayes	56.94	57.41	55.09	56.94	56.94	56.94	53.24	54.17	59.26	57.41	55.09	54.63	58.80	57.41	55.56	
Kernel Naïve Bayes	64.81	62.50	63.89	61.11	60.65	61.57	62.04	59.26	62.50	62.04	59.26	58.80	62.50	62.04	57.87	
Linear SVM	74.54	73.61	72.69	73.15	73.15	72.22	72.22	74.54	72.69	72.22	73.61	70.83	62.04	73.15	71.76	
Quadratic SVM	88.43	84.72	85.19	84.72	86.57	85.65	85.65	86.57	87.96	85.65	87.96	86.11	79.17	87.04	85.19	
Cubic SVM	87.96	87.04	86.57	86.11	89.35	88.43	90.28	90.28	90.28	88.89	88.89	88.43	81.48	87.50	83.80	
Fine Gaussian SVM	72.69	70.37	68.06	75.46	76.85	75.46	80.09	78.70	78.70	78.24	81.02	77.31	75.93	76.39	73.61	
Medium Gaussian SVM	87.96	87.04	85.65	86.57	87.04	84.72	85.19	87.96	87.96	86.11	86.11	85.65	76.39	87.04	86.11	
Coarse Gaussian SVM	62.96	64.35	62.50	65.74	62.96	62.50	61.57	62.50	63.43	63.43	63.89	62.50	53.24	63.89	62.04	
Fine KNN	86.57	85.65	84.72	87.50	85.19	85.19	86.11	88.89	87.96	87.04	87.04	85.65	84.72	86.11	84.26	
Medium KNN	85.65	83.33	81.48	85.19	86.57	82.41	81.94	85.19	83.80	81.02	83.80	85.65	78.70	85.19	83.33	
Coarse KNN	65.28	62.96	62.04	61.11	62.50	62.96	62.96	62.50	61.57	62.96	62.96	59.26	65.74	62.50	60.65	
Cosine KNN	84.26	84.26	77.78	81.02	83.33	81.94	82.41	87.96	84.72	82.41	84.72	84.26	75.00	83.80	81.48	
Cubic KNN	83.80	82.41	81.02	81.94	84.26	79.63	82.87	83.80	81.94	80.09	82.41	83.33	77.31	83.80	80.09	
Weighted KNN	88.43	87.96	85.65	88.43	87.50	86.57	87.50	87.96	86.57	86.11	89.35	88.80	88.43	87.50	85.65	
Boosted Trees	68.52	68.06	68.98	71.30	71.76	69.44	69.91	71.76	71.30	73.15	71.76	70.83	67.13	71.30	69.44	
Bagged Trees	83.33	84.72	87.04	84.72	84.26	84.72	83.33	84.26	84.26	82.41	84.72	83.33	76.85	84.72	81.94	
Subspace Discriminant	69.91	68.98	65.28	58.80	68.06	64.81	60.65	68.98	65.74	62.04	68.52	66.20	56.48	68.98	65.28	
Subspace KNN	66.20	68.52	61.11	59.72	62.96	59.72	70.83	65.28	56.48	62.96	63.89	61.11	52.31	70.37	62.96	
RUSBoosted Trees	64.35	68.98	68.52	69.44	68.98	69.91	66.20	70.37	68.06	67.59	69.91	70.83	62.50	68.52	63.89	
Narrow Neural Network	82.41	78.24	78.24	80.56	79.17	80.09	82.87	77.78	82.41	82.41	70.37	81.94	79.17	74.54		
Medium Neural Network	85.65	79.17	81.48	82.41	81.02	79.63	81.02	81.02	85.19	79.17	84.72	83.33	76.39	82.87	80.56	
Wide Neural Network	82.41	83.33	82.87	83.80	82.41	85.19	81.94	83.80	84.72	86.11	85.65	83.80	74.07	86.57	80.56	
Bilayered Neural Network	81.02	76.39	78.70	75.46	80.56	75.46	83.80	79.63	76.85	84.72	81.94	73.15	81.02	76.85	70.37	
Trilayered Neural Network	75.93	72.69	75.46	77.31	76.39	75.93	81.48	78.70	77.78	78.70	77.31	69.44	77.78	77.78	73.61	
SVM Kernel	67.59	63.43	55.09	57.41	51.85	37.50	69.44	62.96	44.44	62.96	51.85	51.39	37.04	50.00	36.57	43.06
Logistic Regression Kernel	60.65	56.48	52.78	53.70	46.76	35.19	66.20	57.41	49.54	50.46	41.67	47.69	39.35	38.43		

Anexo G – Rankings de caraterísticas

#	Features	Chi2	Features	mRMR	Features	RelieFF	Features	ANOVA	Features	Kruskal
1	rnf_Extenso	288.074	rnf_Extenso	0.3542	median_fng_Extenso	0.0936	sd_Extenso	229.9285	rmpsd_Extenso	138.6994
2	rmpsd_Extenso	220.5346	median_fng_Extenso	0.3224	rnf_Extenso	0.0925	rms_Extenso	229.9101	rms_Extenso	137.3906
3	rns_Extenso	212.8085	ssc_fng_Extenso	0.2814	sd_fng_Extenso	0.0679	rmpsd_Extenso	223.5931	sd_Extenso	137.3806
4	sd_Extenso	212.8085	vl_Flexor	0.0574	sd_fng_Extenso	0.0675	mv_Extenso	198.6286	mv_Extenso	128.4760
5	mv_Extenso	196.4942	kurt_Extenso	0.0424	mean_fng_Extenso	0.0674	iqr_Extenso	150.2087	log_Extenso	108.9581
6	iqr_Extenso	173.3361	sd_fng_Extenso	0.0338	sd_Extenso	0.0671	log_Extenso	144.7663	iqr_Extenso	106.6814
7	log_Extenso	153.3474	rnf_Flexor	0.0258	rns_Extenso	0.0671	rnf_Extenso	137.4518	rnf_Extenso	93.4538
8	median_fng_Extenso	149.9326	rns_Extenso	0.021	rnf_Flexor	0.0617	rns_fng_Extenso	95.0726	kurt_Extenso	86.1923
9	rns_fng_Extenso	122.356	vl_fng_Flexor	0.021	mv_Extenso	0.0581	plf_Extenso	93.9119	rnf_Flexor	85.2050
10	mean_fng_Extenso	107.5057	std_fng_Extenso	0.0192	median_fng_Extenso	0.0550	mean_fng_Extenso	93.6307	rns_fng_Extenso	81.5011
11	pkf_Extenso	96.6648	pkf_Extenso	0.0167	rns_fng_Extenso	0.0496	rns_fng_Extenso	92.3803	mean_fng_Extenso	80.8246
12	rnmf_Flexor	94.4463	iqr_Extenso	0.0152	rns_Flexor	0.0491	mean_fng_Extenso	87.1279	median_fng_Extenso	78.7124
13	rns_Flexor	91.8084	rns_fng_Extenso	0.0149	sd_Flexor	0.0491	std_fng_Flexor	86.9957	mean_fng_Flexor	78.4256
14	sd_Flexor	91.8084	rmpsd_Flexor	0.0141	rns_fng_Flexor	0.0489	median_fng_Extenso	86.8233	rns_fng_Flexor	77.5197
15	std_fng_Flexor	84.4904	kurt_Flexor	0.0134	log_Flexor	0.0484	rnf_Flexor	83.7479	vl_fng_Flexor	77.1138
16	rmpsd_Flexor	83.1959	vl_Extenso	0.0128	mean_fng_Flexor	0.0452	median_fng_Flexor	80.3261	ssc_fng_Flexor	74.1763
17	std_fng_Extenso	79.787	mean_fng_Flexor	0.012	std_fng_Extenso	0.0449	vl_Extenso	80.1576	vl_Extenso	68.3778
18	median_fng_Flexor	76.4749	ssc_fng_Flexor	0.0112	rmpsd_Extenso	0.0433	std_fng_Extenso	61.9769	median_fng_Flexor	68.1877
19	vl_fng_Flexor	75.6473	rmpsd_Extenso	0.011	iqr_Extenso	0.0423	sd_Flexor	53.8255	std_fng_Flexor	66.4288
20	rns_fng_Flexor	74.4634	mean_fng_Extenso	0.0104	mv_Flexor	0.0419	rns_Flexor	53.8195	pkf_Extenso	65.5737
21	mean_fng_Flexor	69.8691	log_Extenso	0.0086	iqr_Flexor	0.0366	ssc_fng_Flexor	45.2249	kurt_Flexor	57.7701
22	kurt_Extenso	64.7263	rns_fng_Flexor	0.0075	ieng_Flexor	0.0293	mar_Flexor	41.8276	std_fng_Extenso	54.6613
23	vl_Extenso	64.245	mv_Extenso	0.0074	vl_Flexor	0.0272	vl_fng_Flexor	41.1725	rmpsd_Flexor	52.2207
24	ssc_fng_Flexor	62.3711	pkf_Flexor	0.0073	pkf_Extenso	0.0242	ieng_Extenso	41.1346	sd_Flexor	50.5566
25	mv_Flexor	61.9726	ssc_Flexor	0.0072	iecng_Extenso	0.0233	rmpsd_Flexor	33.2959	rns_Flexor	50.5483
26	ssc_fng_Extenso	59.14	iecng_Extenso	0.0068	vl_Extenso	0.0211	kurt_Extenso	32.3046	iecng_Extenso	45.1939
27	ieng_Extenso	49.9345	rns_Flexor	0.0064	ssc_fng_Extenso	0.0207	log_Flexor	27.1901	mv_Flexor	39.8220
28	kurt_Flexor	48.4696	sd_Extenso	0.0064	rmpsd_Flexor	0.0203	iqr_Flexor	26.3705	ssc_fng_Extenso	34.6776
29	iqr_Flexor	33.8706	median_fng_Extenso	0.0061	ssc_fng_Flexor	0.0129	kurt_Flexor	22.9255	ssc_Flexor	34.4832
30	vl_fng_Extenso	32.8508	mv_Flexor	0.0042	kurt_Extenso	0.0128	ssc_fng_Extenso	19.0875	log_Flexor	23.7157
31	log_Flexor	31.827	vl_fng_Extenso	0.003	vl_fng_Flexor	0.0103	ssc_Flexor	17.0826	iqr_Flexor	23.5321
32	ssc_Flexor	30.5902	sd_Flexor	0.0026	vl_fng_Extenso	0.0103	vl_fng_Extenso	16.4307	iecng_Flexor	18.0687
33	iecng_Flexor	26.2715	ssc_Extenso	0.0022	kurt_Flexor	0.0090	iecng_Flexor	13.3500	vl_Flexor	16.4125
34	vl_Flexor	20.1538	log_Flexor	0.0019	ssc_Extenso	0.0080	pkf_Flexor	12.9529	vl_fng_Extenso	16.3612
35	ssc_Extenso	16.9341	iecng_Flexor	0.0018	ssc_Flexor	0.0072	wl_Flexor	11.0163	ssc_Extenso	14.2143
36	pkf_Flexor	10.2292	iecng_Flexor	0.0014	pkf_Flexor	0.0067	ssc_Extenso	8.3199	pkf_Flexor	12.5059



**Instituto Superior
de Engenharia**

Politécnico de Coimbra